ANALISIS KETAHANAN *MODEL TRANSFER LEARNING MOBILENETV2* DAN *RESNET50* TERHADAP KOMPRESI CITRA PADA KLASIFIKASI WAJAH *DEEPFAKE*

SKRIPSI

Diajukan Untuk Memenuhi Salah Satu Syarat

Memperoleh Gelar Strata Satu (S1) Teknik Informatika

Oleh:

NASRULLOH ARRIZIQ

NIM: 221351106

PROGRAM STUDI TEKNIK INFORMATIKA

SEKOLAH TINGGI TEKNOLOGI WASTUKANCANA

PURWAKARTA

2026

LEMBAR PENGESAHAN PEMBIMBING

ANALISIS KETAHANAN *MODEL TRANSFER LEARNING MOBILENETV2* DAN *RESNET50* TERHADAP KOMPRESI CITRA PADA KLASIFIKASI WAJAH *DEEPFAKE*

Oleh:
Nasrulloh Arriziq
221351106
Program Studi Teknik Informatika

Sekolah Tinggi Teknologi Wastukancana Purwakarta

Menyetujui,

Tim Pembimbing

Tanggal 30 Juli 2026

Pembimbing Utama	Pembimbing Pendamping
Syariful Alam, M.Kom.	**Chandra Dewi Lestari, M.T.**
NIDN: 0426106902	NIDN: 0416097901

Mengetahui,

Ketua Program Studi Teknik Informatika

Teguh Iman Hermanto, S.Kom., M.Kom.
NIDN: 0425049102

LEMBAR PENGESAHAN PENGUJI

ANALISIS KETAHANAN *MODEL TRANSFER LEARNING MOBILENETV2* DAN *RESNET50* TERHADAP KOMPRESI CITRA PADA KLASIFIKASI WAJAH *DEEPFAKE*

Oleh:
Nasrulloh Arriziq
221351106
Program Studi Teknik Informatika

Sekolah Tinggi Teknologi Wastukancana Purwakarta

Menyetujui,

Tim Penguji

Tanggal 30 Juli 2026

Ketua Penguji	Anggota Penguji
Ismi Kaniawulan, S.T., M.T.	**Meriska Defriani, S.Komp., M.Kom.**
NIDN: 0023077601	NIDN: 0416129004

Mengetahui,

Ketua Program Studi Teknik Informatika

Teguh Iman Hermanto, S.Kom., M.Kom.
NIDN: 0425049102

PERNYATAAN

Saya Nasrulloh Arriziq menyatakan dengan sesungguhnya, bahwa karya tulis yang berjudul **"Analisis Ketahanan *Model Transfer Learning* MobileNetV2 dan ResNet50 Terhadap Kompresi Citra Pada Klasifikasi Wajah *Deepfake*"** adalah benar hasil karya sendiri. Serta tidak terdapat karya yang pernah diajukan untuk memperoleh gelar kesarjanaan disuatu perguruan tinggi, dan sepengetahuan saya tidak terdapat karya atau pendapat yang pernah ditulis/diterbitkan orang lain, kecuali yang tertulis diacu dalam naskah ini dan disebutkan dalam daftar pustaka.

Purwakarta, 30 Juli 2026

ttd+Materai 10.000

Nasrulloh Arriziq
NIM. 221351106

PEDOMAN PENGGUNAAN SKRIPSI

Skripsi S1 yang tidak dipublikasikan terdaftar dan tersedia di Perpustakaan Sekolah Tinggi Teknologi Wastukancana, dan terbuka untuk umum dengan ketentuan bahwa hak cipta ada pada pengarang dengan mengikuti aturan HaKI yang berlaku di Sekolah Tinggi Teknologi Wastukancana. Referensi kepustakaan diperkenankan dicatat, tetapi pengutipan atau peringkasan hanya dapat dilakukan seizin pengarang dan harus disertai dengan kebiasaan ilmiah untuk menyebutkan sumbernya.

Memperbanyak atau menerbitkan sebagian atau seluruh Skripsi haruslah seizin Ketua Sekolah Tinggi Teknologi Wastukancana Purwakarta.

ABSTRAK

ANALISIS KETAHANAN *MODEL TRANSFER LEARNING MOBILENETV*2 DAN *RESNET50* TERHADAP KOMPRESI CITRA PADA KLASIFIKASI WAJAH *DEEPFAKE*

Oleh

NASRULLOH ARRIZIQ

NIM: 221351106

Penyebaran manipulasi citra wajah (*deepfake*) di media sosial menghadirkan ancaman serius terhadap integritas informasi digital. Meskipun berbagai model deteksi *deepfake* telah dikembangkan, sebagian besar model tersebut rentan mengalami penurunan performa secara drastis ketika dihadapkan pada gambar yang mengalami degradasi akibat algoritma kompresi saat diunggah ke *platform* media sosial. Penelitian ini bertujuan untuk menganalisis dan membandingkan tingkat ketahanan (*robustness*) antara arsitektur *Convolutional Neural Network* (CNN) berbobot ringan (MobileNetV2) dan arsitektur dalam (ResNet50) dalam mengklasifikasikan citra *deepfake* yang terkompresi. Penelitian ini menggunakan pendekatan kuantitatif eksperimental dengan metode *Transfer Learning* berbasis *Feature Extraction*, menggunakan fungsi aktivasi *Sigmoid* untuk klasifikasi biner. Dataset yang digunakan adalah Celeb-DF v2 versi *pre-cropped faces* yang diseimbangkan menjadi rasio 1:1 (40.288 citra asli dan 40.288 citra palsu) menggunakan *Random Undersampling*. Pengujian batas ketahanan (*stress-testing*) dilakukan dengan mensimulasikan degradasi kualitas kompresi JPEG dari *Quality Factor* (QF) 100 hingga tingkat ekstrem QF 30 menggunakan pustaka pemrograman *Python* di lingkungan *Google Colab*, serta diimplementasikan ke dalam purwarupa aplikasi antarmuka menggunakan *framework* Streamlit. Hasil evaluasi menunjukkan bahwa MobileNetV2 memiliki ketahanan yang jauh lebih superior, dengan akurasi mencapai 83% pada kondisi ideal (QF 100) dan hanya mengalami penurunan minimal menjadi 81% pada kompresi ekstrem (QF 30). Sebaliknya, arsitektur ResNet50 gagal beradaptasi dengan kompresi, hanya mencapai akurasi maksimal 70% dan menghasilkan tingkat *False Positive* yang ekstrem akibat fenomena *over-smoothing* pada saat mengekstraksi piksel yang rusak. Kesimpulan dari penelitian ini merekomendasikan penggunaan MobileNetV2 sebagai arsitektur yang paling optimal dan objektif untuk diimplementasikan pada sistem deteksi *deepfake* di lingkungan digital dunia nyata.

Kata Kunci: *Deepfake*, Kompresi JPEG, *MobileNetV2*, *ResNet50*, *Transfer Learning*

ABSTRACT

ROBUSTNESS ANALYSIS OF MOBILENETV2 AND RESNET50 TRANSFER LEARNING MODELS AGAINST IMAGE COMPRESSION IN DEEPFAKE FACE CLASSIFICATION

By:

NASRULLOH ARRIZIQ

NIM: 221351106

The proliferation of facial image manipulation (deepfakes) on social media poses a serious threat to the integrity of digital information. Although various deepfake detection models have been developed, most suffer from drastic performance degradation when faced with images degraded by compression algorithms during social media uploads. This study aims to analyze and compare the robustness of a lightweight Convolutional Neural Network (CNN) architecture (MobileNetV2) versus a deep architecture (ResNet50) in classifying compressed deepfake images. An experimental quantitative approach was employed using a feature-extraction-based Transfer Learning method and a Sigmoid activation function for binary classification. The dataset utilized was the pre-cropped face version of Celeb-DF v2, balanced to a 1:1 ratio (40,288 real images and 40,288 fake images) via random undersampling. Stress testing was conducted by simulating JPEG compression quality degradation—ranging from a Quality Factor (QF) of 100 down to an extreme QF of 30 using Python libraries in a Google Colab environment, with the models subsequently implemented in a prototype interface using the Streamlit framework. Evaluation results demonstrate that MobileNetV2 exhibits far superior robustness, achieving 83% accuracy under ideal conditions (QF 100) and experiencing only a minimal drop to 81% under extreme compression (QF 30). Conversely, the ResNet50 architecture failed to adapt to compression, achieving a maximum accuracy of only 70% and producing extreme False Positive rates due to over-smoothing when processing degraded pixels. The study concludes by recommending MobileNetV2 as the optimal architecture for implementation in real-world deepfake detection systems.

Keywords: Deepfake, JPEG Compression, MobileNetV2, ResNet50, Transfer Learning

KATA PENGANTAR

Puja dan puji syukur kehadirat Allah SWT yang Maha Pengasih lagi Maha Penyayang, yang telah melimpahkan rahmat, hidayah, dan inayah-Nya, sehingga penulis dapat merampungkan skripsi yang berjudul "Analisis Ketahanan *Model Transfer Learning* MobileNetV2 dan ResNet50 Terhadap Kompresi Citra Pada Klasifikasi Wajah *Deepfake*".

Melalui kesempatan yang berharga dan dengan menyelesaikan skripsi ini penulis banyak mendapatkan arahan, bimbingan, doa, serta dukungan dari berbagai pihak baik secara langsung maupun tidak langsung. Oleh sebab itu, penulis ingin mengucapkan terimakasih kepada yang terhormat :

1. Bapak Dr. Ir. Apang Djafar Shieddieque, S.T., M.T. IPM., ASEAN Eng. Selaku Ketua Sekolah Tinggi Teknologi Wastukancana Purwakarta.
2. Bapak Teguh Iman Hermanto, S.Kom, M.Kom. Selaku Kaprodi Teknik Informatika.
3. Bapak Syariful Alam, M.kom. Selaku pembimbing utama.
4. Ibu Chandra Dewi Lestari, M.T. Selaku Pembimbing Pendamping.
5. Seluruh Keluarga Besar yang telah mendukung sepenuh hati dan memberikan dukungan baik secara moril maupun materi.
6. Grup musik Perunggu, terima kasih atas lagu-lagunya yang telah menjadi teman setia, penghibur di kala lelah, dan pengingat bagi penulis untuk terus melangkah menyelesaikan tugas akhir ini.

Penulis menyadari bahwa skripsi ini masih jauh dari kata sempurna dan masih memiliki kekurangan. Penulis mengharapkan kritik dan saran pembaca untuk menyempurnakan skripsi ini. Semoga skripsi ini bermanfaat bagi semua pihak yang membutuhkannya. Akhir kata, semoga Allah SWT melimpahkan rahmat dan hidayah-Nya kepada kita semua. Amin ya robbal 'alamiin.

Purwakarta, 30 Juli 2026

Nasrulloh Arriziq

DAFTAR ISI

LEMBAR PENGESAHAN PEMBIMBING

LEMBAR PENGESAHAN PENGUJI

PERNYATAAN i

PEDOMAN PENGGUNAAN SKRIPSI ii

ABSTRAK iii

ABSTRACT iv

KATA PENGANTAR v

DAFTAR ISI vi

DAFTAR TABEL ix

DAFTAR GAMBAR x

BAB I PENDAHULUAN 1

1.1 Latar Belakang 1

1.2 Rumusan Masalah 4

1.3 Batasan Masalah 4

1.4 Tujuan Penelitian 5

1.5 Manfaat Penelitian 5

1.5.1 Manfaat Teoritis 5

1.5.2 Manfaat Praktis 5

1.6 Sistematika Penulisan 6

BAB II TINJAUAN PUSTAKA 7

2.1 *Deepfake* dan Manipulasi Wajah Digital 7

2.2 Kompresi Citra dan Degradasi Visual 8

2.3 *Convolutional Neural Network* (CNN) 8

2.4 Pendekatan *Transfer Learning* 10

2.4.1 Arsitektur *MobileNetV2* 10

2.4.2 Arsitektur ResNet50 11
2.5 Metrik Evaluasi Kinerja *Model* 12
2.5.1 *Confusion Matrix* 13
2.5.2 Akurasi (*Accuracy*) 13
2.5.3 Presisi (*Precision*) 13
2.5.4 *Recall* 14
2.6 Ketahanan *Model* (*Robustness*) dalam Pembelajaran Mesin 14
2.7 Penelitian Terdahulu 15
2.8 Kerangka Berpikir 21
BAB III METODOLOGI PENELITIAN 23
3.1 Tahapan Penelitian 23
3.2 Objek Penelitian 25
3.3 Jadwal Penelitian 26
3.4 Metode Penelitian 26
3.4.1 Jenis Penelitian 26
3.4.3 *Dataset* 27
3.4.4 *Preprocessing* Data 27
3.4.5 Skenario Kompresi Citra 28
3.4.6 Arsitektur *Model* 28
3.4.7 Proses Pelatihan dan Pengujian 29
3.4.8 Evaluasi Kinerja *Model* 30
3.4.9 Analisis Komparasi *Model* 31
BAB IV HASIL DAN PEMBAHASAN 32
4.1 Pengumpulan Data 32
4.2 Pra-Pemrosesan dan Penyeimbangan Kelas 32
4.3 Skenario Pengujian 33

4.4 Hasil Pelatihan Model 34
4.4.1 Proses Pelatihan *MobileNetV2* 35
4.4.2 Proses Pelatihan ResNet50 36
4.5 Hasil Evaluasi dan Komparasi Model 37
4.6 Analisis dan Pembahasan 38
4.6.1 Dampak Kompresi JPEG Terhadap Ketahanan Deteksi 38
4.6.2 Analisis Karakteristik Klasifikasi dan Perilaku Model 39
4.7 Implementasi Purwarupa Sistem 39
4.7.1 Perancangan Fungsionalitas Sistem (*Use Case Diagram*) 40
4.7.2 Alur Kerja dan Antarmuka Pengguna 41
BAB V KESIMPULAN DAN SARAN 42
5.1 Kesimpulan 42
5.2 Saran 42
DAFTAR PUSTAKA 44

DAFTAR TABEL

Tabel 2. 1 Penelitian Terdahulu..... 15
Tabel 3. 1 Jadwal Penelitian 26
Tabel 4. 1 Metrik Komparasi Performa Model terhadap Hasil Kompresi Citra ... 37

DAFTAR GAMBAR

Gambar 2. 1 Arsitektur MobileNetV2 dan ResNet50 [4] 12
Gambar 2. 2 Kerangka Berpikir 22
Gambar 3. 1 Tahapan Penelitian 23
Gambar 4. 1 Grafik Distribusi Sebelum dan Sesudah *Undersampling*..... 33
Gambar 4. 2 Kualitas Citra Wajah pada Berbagai Tingkat Kompresi JPEG 34
Gambar 4. 3 Grafik Akurasi *MobileNetV2* 35
Gambar 4. 4 Grafik Akurasi ResNet50..... 36
Gambar 4. 5 *Use Case Diagram* Sistem Deteksi *Deepfake*..... 40
Gambar 4. 6 Tampilan Antarmuka Purwarupa Sistem 41

BAB I
PENDAHULUAN

1.1 Latar Belakang

Kemajuan metode berbasis kecerdasan buatan (*artificial intelligence*), khususnya dalam bidang visi komputer, telah mendorong kemajuan signifikan dalam pengolahan dan manipulasi citra digital. Salah satu fenomena yang berkembang pesat adalah teknologi *deepfake*, yaitu teknik manipulasi wajah berbasis *model* generatif yang mampu menghasilkan citra wajah tiruan dengan tingkat kemiripan yang sangat tinggi terhadap individu asli. Kemajuan ini memberikan dampak positif dalam industri kreatif, namun di sisi lain juga menimbulkan berbagai permasalahan serius, seperti penyebaran informasi palsu, penipuan identitas, serta penyalahgunaan media digital. Seiring dengan meningkatnya kualitas teknologi *deepfake*, kemampuan manusia dalam membedakan citra asli dan manipulasi menjadi semakin terbatas, sehingga diperlukan sistem otomatis yang mampu melakukan deteksi secara akurat dan konsisten.

Dalam upaya mengatasi permasalahan tersebut, berbagai penelitian telah memanfaatkan metode berbasis *Convolutional Neural Network* (CNN) yang memiliki kemampuan dalam mengekstraksi fitur spasial dari citra secara otomatis. Untuk meningkatkan performa *model*, pendekatan *transfer learning* banyak digunakan dengan memanfaatkan *model pre-trained* yang telah dilatih pada *dataset* berskala besar. Pendekatan ini terbukti efektif dalam meningkatkan akurasi serta efisiensi pelatihan, terutama pada kondisi keterbatasan data. Dengan demikian, CNN berbasis *transfer learning* menjadi salah satu solusi utama dalam pengembangan sistem deteksi *deepfake* berbasis citra. Selain itu, sebelum proses ekstraksi fitur dilakukan oleh *model* CNN, diperlukan tahapan *preprocessing* yang presisi. Salah satu tahap penting adalah ekstraksi area wajah (*face cropping*) menggunakan metode deteksi wajah, sehingga *model* dapat fokus pada karakteristik struktural wajah dan mengurangi pengaruh *noise* dari latar belakang. [1]

Sejumlah penelitian terdahulu menunjukkan bahwa pendekatan ini mampu memberikan performa yang tinggi dalam mendeteksi citra *deepfake*. Penelitian oleh [2] menunjukkan bahwa *model* seperti MobileNetV2, ResNet50, InceptionV3, dan EfficientNet memiliki kemampuan yang baik dalam membedakan citra wajah asli dan manipulasi. Dalam penelitian tersebut, MobileNetV2 memperoleh akurasi tertinggi sebesar 89%, diikuti oleh ResNet50 dengan akurasi sebesar 83%. Hal ini menunjukkan bahwa MobileNetV2 dan ResNet50 tidak hanya memiliki akurasi yang tinggi, tetapi juga representatif untuk digunakan sebagai *baseline model* dalam penelitian deteksi *deepfake* berbasis citra.

Pemilihan MobileNetV2 dan ResNet50 sebagai arsitektur dalam penelitian ini didasarkan pada tingkat popularitas dan penggunaannya yang sangat masif, baik di kalangan akademisi maupun industri visi komputer. Berdasarkan data indeks Google Scholar, arsitektur dasar ResNet telah menjadi salah satu rujukan utama di dunia global dengan lebih dari 300.000 sitasi sejak diperkenalkan oleh [3]. Sementara itu, MobileNetV2 yang dirancang khusus untuk efisiensi komputasi telah disitasi lebih dari 30.000 kali [4]. Tingginya tingkat adopsi kedua arsitektur ini menjadikannya representasi yang paling ideal dan valid untuk menguji ketahanan *model* standar terhadap masalah degradasi citra di dunia nyata.

Namun demikian, performa tinggi yang diperoleh dalam kondisi penelitian tidak selalu mencerminkan kinerja *model* pada kondisi dunia nyata. Dalam praktiknya, citra digital yang beredar di media sosial atau aplikasi komunikasi umumnya telah mengalami proses kompresi yang dapat menurunkan kualitas visual. Secara matematis, inti dari degradasi informasi pada kompresi JPEG terjadi pada tahap kuantisasi koefisien *Discrete Cosine Transform* (DCT), yang dirumuskan sebagai persamaan berikut:

$$F^{Q(u,v)} = round(\frac{F(u,v)}{Q_{QF(u,v)}})$$

di mana $F(u,v)$ adalah matriks koefisien DCT dari blok citra input $Q_{QF(u,v)}$, adalah matriks kuantisasi yang telah diskalakan besaran nilainya berdasarkan *Quality Factor* (QF), dan $F^{Q(u,v)}$ adalah hasil koefisien yang telah dikuantisasi.
Proses pembagian dan pembulatan numerik (round) pada persamaan tersebut bersifat *irreversible* (tidak dapat dikembalikan nilainya secara utuh), yang secara

mekanis menyebabkan hilangnya informasi visual pada komponen frekuensi tinggi. Proses kompresi tersebut dapat menyebabkan hilangnya detail penting, munculnya artefak visual, serta perubahan distribusi piksel, yang pada akhirnya dapat mempengaruhi kemampuan model dalam mengekstraksi fitur secara optimal. Kondisi matematis inilah yang menimbulkan tantangan baru dalam pengembangan sistem deteksi *deepfake*, karena model CNN yang dilatih pada data berkualitas tinggi belum tentu mampu mempertahankan performanya ketika dihadapkan pada citra yang telah terkompresi [5].

Proses pembagian numerik pada persamaan kuantisasi tersebut bersifat *irreversible* (tidak dapat dikembalikan secara utuh), yang secara mekanis menyebabkan hilangnya informasi visual pada komponen frekuensi tinggi. Proses kompresi tersebut dapat menyebabkan hilangnya detail penting, munculnya artefak visual, serta perubahan distribusi piksel, yang pada akhirnya dapat mempengaruhi kemampuan model dalam mengekstraksi fitur secara optimal. Kondisi ini menimbulkan tantangan baru dalam pengembangan sistem deteksi *deepfake*, karena model yang dilatih pada data berkualitas tinggi belum tentu mampu mempertahankan performanya ketika dihadapkan pada citra yang telah terkompresi [6].

Hal ini menunjukkan adanya *research gap* yang signifikan, khususnya dalam mengevaluasi ketahanan (*robustness*) *model* terhadap citra yang mengalami degradasi kualitas akibat kompresi, yang hingga saat ini masih belum banyak dieksplorasi secara sistematis dalam penelitian sebelumnya. Sebagian besar penelitian masih berfokus pada pengujian *model* dalam kondisi *dataset* ideal, tanpa mempertimbangkan variasi kualitas citra yang umum terjadi dalam penggunaan nyata. Oleh karena itu, penelitian ini bertujuan untuk mengembangkan sistem klasifikasi citra wajah *real* dan *deepfake* menggunakan pendekatan CNN berbasis *transfer learning*, serta melakukan analisis ketahanan *model*, khususnya MobileNetV2 dan ResNet50, terhadap citra dengan berbagai tingkat kompresi. Dengan demikian, penelitian ini diharapkan dapat memberikan gambaran yang lebih representatif mengenai performa *model* dalam kondisi dunia nyata sekaligus menjadi kontribusi dalam pengembangan sistem deteksi *deepfake* yang lebih andal.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang sudah diuraikan, berikut rumusan masalah:

1. Bagaimana performa dan perbandingan kinerja arsitektur *transfer learning* MobileNetV2 dan ResNet50 dalam mengklasifikasikan citra wajah *real* dan *deepfake* pada kondisi citra ideal?
2. Bagaimana pengaruh degradasi kualitas citra akibat kompresi terhadap ketahanan (*robustness*) arsitektur MobileNetV2 dan ResNet50 dalam mendeteksi citra *deepfake*?

1.3 Batasan Masalah

Agar penelitian ini tetap terfokus, terukur, dan dapat dicapai sesuai dengan standar rekayasa perangkat lunak tingkat sarjana, ruang lingkup penelitian dibatasi pada parameter berikut:

1. Penelitian ini berfokus secara eksklusif pada klasifikasi citra wajah statis menjadi dua kelas (*real* dan *deepfake*), dan tidak memproses data dalam bentuk sekuensial atau video.
2. Metode klasifikasi dibatasi pada pemanfaatan *Convolutional Neural Network* (CNN) dengan pendekatan *transfer learning*, secara spesifik menggunakan arsitektur **MobileNetV2** dan **ResNet50**.
3. *Dataset* utama menggunakan turunan dari dataset publik *Celeb-DF v2* yang telah berupa subset citra wajah statis terpotong (*pre-cropped faces*). Oleh karena itu, tahap *preprocessing* dibatasi pada penyesuaian dimensi resolusi citra dan simulasi kompresi JPEG (*Joint Photographic Experts Group)*.
4. Parameter degradasi kualitas citra disimulasikan secara spesifik pada variasi tingkat kompresi (misalnya kompresi JPEG pada rasio tertentu) untuk meniru kondisi penyebaran media di dunia nyata.
5. Evaluasi performa difokuskan pada analisis ketahanan *model* (*robustness*) terhadap kompresi citra menggunakan metrik standar (*Accuracy, Precision, Recall*, dan *Confusion Matrix*), tanpa melakukan optimasi hiperparameter tingkat lanjut atau modifikasi arsitektur dasar.

6. Hasil akhir *model* diimplementasikan ke dalam purwarupa aplikasi berbasis antarmuka sederhana (seperti skrip Python atau aplikasi web *Streamlit*/*Gradio*) murni untuk keperluan demonstrasi klasifikasi.

1.4 Tujuan Penelitian

Sejalan dengan rumusan masalah di atas, penelitian ini memiliki tujuan yang spesifik dan terukur sebagai berikut:

1. Menganalisis dan membandingkan performa arsitektur *transfer learning* MobileNetV2 dan ResNet50 dalam mengklasifikasikan citra wajah *real* dan *deepfake* pada kondisi *dataset* ideal.
2. Mengevaluasi pengaruh degradasi kualitas citra akibat kompresi terhadap tingkat ketahanan (*robustness*) dari arsitektur MobileNetV2 dan ResNet50 dalam mendeteksi citra *deepfake*.

1.5 Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan kontribusi yang terukur, baik dari sisi pengembangan ilmu komputer maupun implementasi di masyarakat, yang dijabarkan ke dalam dua aspek berikut:

1.5.1 Manfaat Teoritis

Secara teoritis, penelitian ini diharapkan dapat memberikan kontribusi pada pengembangan ilmu komputer dengan rincian sebagai berikut:

1. Menjadi rujukan literatur dan kontribusi akademis terkait implementasi *transfer learning* (khususnya MobileNetV2 dan ResNet50) pada pemrosesan citra digital.
2. Memberikan wawasan empiris mengenai dampak kompresi citra terhadap penurunan performa *model Convolutional Neural Network* (CNN) dalam mendeteksi manipulasi wajah.

1.5.2 Manfaat Praktis

Secara praktis, penelitian ini diharapkan dapat mendukung implementasi di masyarakat dengan rincian sebagai berikut:

1. Menghasilkan *model* deteksi *deepfake* yang telah teruji ketahanannya pada kualitas citra yang dikompresi, sehingga lebih relevan dengan kondisi penyebaran media di platform sosial.
2. Memberikan landasan bagi pengembang sistem keamanan digital dalam merancang aplikasi pendeteksi *deepfake* yang efisien dan tangguh.

1.6 Sistematika Penulisan

Untuk memberikan gambaran yang jelas mengenai penyusunan skripsi ini, penulisan dibagi menjadi lima bab dengan sistematika sebagai berikut:

1. BAB I PENDAHULUAN: Membahas latar belakang masalah terkait *deepfake* dan kompresi citra, rumusan masalah, tujuan penelitian, batasan masalah, manfaat penelitian, serta sistematika penulisan.
2. BAB II TINJAUAN PUSTAKA: Menguraikan landasan teori yang mendukung penelitian, seperti konsep *Deepfake*, *Convolutional Neural Network* (CNN), *Transfer Learning* (MobileNetV2 & ResNet50).
3. BAB III METODOLOGI PENELITIAN: Menjelaskan tahapan sistematis penelitian, mulai dari pengumpulan *dataset* (seperti *Celeb-DF v2*), *preprocessing* data (ekstraksi wajah dan simulasi kompresi), arsitektur sistem yang diusulkan, hingga skenario pengujian *model*.
4. BAB IV HASIL DAN PEMBAHASAN: Menyajikan hasil pengujian *model*, perbandingan performa antara MobileNetV2 dan ResNet50, serta analisis mendalam mengenai pengaruh kompresi terhadap tingkat akurasi dan ketahanan (*robustness*) *model*.
5. BAB V KESIMPULAN DAN SARAN: Berisi kesimpulan yang menjawab rumusan dan tujuan penelitian, serta memberikan saran-saran konstruktif untuk pengembangan penelitian deteksi *deepfake* di masa mendatang.

BAB II
TINJAUAN PUSTAKA

2.1 *Deepfake* dan Manipulasi Wajah Digital

Deepfake merupakan salah satu bentuk manipulasi media digital yang dihasilkan melalui pemanfaatan teknologi kecerdasan buatan, khususnya dalam bidang pembelajaran mendalam (*deep learning*). Secara umum, *deepfake* mengacu pada proses sintesis citra atau video yang menggabungkan atau menggantikan wajah seseorang dengan wajah individu lain secara *real*istis. Teknik ini biasanya dibangun menggunakan *model* generatif seperti *autoencoder* dan *Generative Adversarial Network* (GAN), yang mampu mempelajari distribusi data wajah dan menghasilkan representasi visual yang menyerupai data asli. Dengan dukungan metode berbasis *Convolutional Neural Network*, sistem *deepfake* dapat mengekstraksi serta merekonstruksi fitur wajah secara detail, sehingga menghasilkan citra manipulasi yang sulit dibedakan oleh pengamatan manusia.[7]

Meskipun memiliki potensi positif dalam bidang hiburan, perfilman, dan industri kreatif, perkembangan teknologi *deepfake* juga menimbulkan ancaman yang signifikan. Kemampuan untuk menghasilkan konten visual yang tampak autentik membuka peluang penyalahgunaan, seperti penyebaran disinformasi, manipulasi opini publik, serta penipuan identitas. Selain itu, peningkatan kualitas hasil sintesis membuat batas antara konten asli dan manipulasi menjadi semakin kabur, sehingga menurunkan tingkat kepercayaan terhadap media digital. Kondisi ini diperparah dengan kemudahan akses terhadap teknologi *deepfake*, yang memungkinkan pengguna tanpa keahlian teknis tinggi untuk menghasilkan konten manipulatif. Oleh karena itu, *deepfake* tidak hanya menjadi permasalahan teknis dalam bidang visi komputer, tetapi juga berkembang menjadi isu keamanan informasi dan etika digital yang memerlukan perhatian serius.[8].

2.2 Kompresi Citra dan Degradasi Visual

Kompresi citra merupakan teknik yang digunakan untuk mengurangi ukuran file gambar dengan tujuan efisiensi penyimpanan dan transmisi data [9]. Salah satu metode kompresi yang paling umum digunakan adalah kompresi *loss*y seperti JPEG (*Joint Photographic Experts Group)*, yang banyak diterapkan pada berbagai platform digital, termasuk media sosial dan aplikasi perpesanan. Metode ini bekerja dengan mengurangi redundansi data serta menghilangkan informasi visual yang dianggap kurang penting bagi persepsi manusia [10]. Proses kompresi JPEG umumnya melibatkan transformasi domain frekuensi, kuantisasi, serta pengkodean ulang, yang secara signifikan dapat menurunkan jumlah data yang disimpan dalam citra [11].

Meskipun efektif dalam mengurangi ukuran file, kompresi *loss*y seperti JPEG menyebabkan hilangnya detail spasial pada citra, terutama pada komponen frekuensi tinggi yang merepresentasikan tekstur halus, tepi objek, dan detail wajah. Selain itu, proses kuantisasi yang agresif dapat menghasilkan berbagai artefak visual, seperti *blocking artifact*, *blurring*, dan *ringing*, yang menyebabkan distorsi pada struktur piksel [12]. Artefak-artefak ini sering kali tidak terlalu terlihat oleh mata manusia, namun memiliki dampak signifikan terhadap representasi fitur yang digunakan oleh *model* berbasis *Convolutional Neural Network*.

Dalam konteks deteksi *deepfake*, keberadaan artefak dan hilangnya informasi visual akibat kompresi dapat mengganggu kemampuan *model* dalam mengekstraksi fitur penting yang membedakan citra asli dan manipulasi [13]. *Model* CNN sangat bergantung pada pola tekstur, tepi, dan distribusi piksel untuk melakukan klasifikasi [14]. Ketika informasi tersebut terdistorsi atau hilang, representasi fitur yang dihasilkan menjadi kurang akurat, sehingga berpotensi menurunkan performa *model* [15]. Dengan demikian, kompresi citra tidak hanya mempengaruhi kualitas visual, tetapi juga berdampak langsung pada kinerja sistem pembelajaran mesin, khususnya dalam tugas klasifikasi citra *deepfake* [16].

2.3 *Convolutional Neural Network* (CNN)

Convolutional Neural Network (CNN) merupakan salah satu arsitektur jaringan saraf tiruan yang digunakan dalam bidang visi komputer, khususnya untuk

tugas klasifikasi citra [17], [18]. CNN dirancang untuk secara otomatis mengekstraksi fitur dari data berbentuk grid, seperti gambar, dengan memanfaatkan operasi konvolusi [19]. Berbeda dengan metode tradisional yang memerlukan ekstraksi fitur secara manual, CNN mampu mempelajari representasi fitur secara hierarkis langsung dari data mentah [20]. Hal ini menjadikan CNN sangat efektif dalam mengenali pola visual kompleks, seperti tekstur, bentuk, dan struktur objek dalam citra [21].

Arsitektur dasar CNN terdiri dari beberapa komponen utama, yaitu *convolutional layer*, *pooling layer*, dan *fully connected layer* [22], [23]. *Convolutional layer* berfungsi sebagai tahap utama dalam ekstraksi fitur, di mana kernel atau filter digeser di seluruh citra input untuk menghasilkan *feature map*. Setiap filter dirancang untuk mendeteksi pola tertentu, seperti tepi (*edge*), sudut, atau tekstur [24]. Semakin dalam lapisan CNN, fitur yang dipelajari menjadi semakin kompleks, mulai dari pola sederhana hingga representasi objek yang lebih abstrak [25]. Proses ini memungkinkan CNN untuk memahami struktur visual citra secara bertingkat.

Selanjutnya, *pooling layer* digunakan untuk mengurangi dimensi *feature map* tanpa menghilangkan informasi penting. Operasi ini bertujuan untuk menekan jumlah parameter, mengurangi risiko *overfitting*, serta meningkatkan efisiensi komputasi. Salah satu metode yang umum digunakan adalah *max pooling*, yang mengambil nilai maksimum dari setiap wilayah lokal pada *feature map*. Dengan demikian, CNN menjadi lebih robust terhadap variasi kecil pada posisi objek dalam citra.

Pada tahap akhir, *fully connected layer* berfungsi untuk melakukan proses klasifikasi berdasarkan fitur yang telah diekstraksi [26]. Lapisan ini menghubungkan seluruh neuron dari lapisan sebelumnya dan menghasilkan output berupa probabilitas untuk setiap kelas [27]. Dalam konteks penelitian ini, output yang dihasilkan adalah klasifikasi citra wajah ke dalam dua kategori, yaitu *real* dan *deepfake* [28]. Dengan kombinasi ketiga komponen tersebut, CNN mampu mengekstraksi dan mempelajari fitur spasial dari citra secara efektif, sehingga menjadi dasar utama dalam pengembangan sistem deteksi *deepfake* berbasis citra.

2.4 Pendekatan *Transfer Learning*

Transfer learning merupakan teknik dalam pembelajaran mesin yang memanfaatkan *model* yang telah dilatih sebelumnya (*pre-trained model*) pada *dataset* berskala besar untuk menyelesaikan tugas baru yang serupa [17]. Dalam konteks visi komputer, *model* biasanya dilatih pada *dataset* umum seperti ImageNet, sehingga telah memiliki kemampuan awal dalam mengenali berbagai pola visual dasar, seperti tepi, tekstur, dan bentuk [18], [29]. Dengan memanfaatkan pengetahuan tersebut, proses pelatihan pada *dataset* baru menjadi lebih efisien, baik dari segi waktu maupun kebutuhan data [30].

Pendekatan *transfer learning* umumnya dilakukan dengan cara mempertahankan bobot pada lapisan awal *model* (yang berfungsi sebagai ekstraktor fitur) dan hanya melatih ulang lapisan akhir (*fine-tuning*) untuk menyesuaikan dengan tugas spesifik, seperti klasifikasi citra wajah *real* dan *deepfake* [29], [31]. Strategi ini sangat bermanfaat ketika *dataset* yang tersedia terbatas, karena *model* tidak perlu belajar dari nol [17], [30]. Dalam penelitian ini, *transfer learning* digunakan untuk memanfaatkan kemampuan arsitektur CNN yang telah terbukti efektif, sehingga diharapkan dapat meningkatkan performa klasifikasi sekaligus mempercepat proses pelatihan [18], [28].

2.4.1 Arsitektur *MobileNetV2*

MobileNetV2 merupakan salah satu arsitektur CNN yang dirancang dengan fokus pada efisiensi komputasi dan penggunaan memori yang rendah. *Model* ini sangat cocok untuk implementasi pada perangkat dengan keterbatasan sumber daya, seperti perangkat mobile atau sistem dengan spesifikasi terbatas. Keunggulan utama MobileNetV2 terletak pada penggunaan teknik *depthwise separable convolution*, yaitu pemisahan operasi konvolusi menjadi dua tahap: *depthwise convolution* dan *pointwise convolution*. Pendekatan ini secara signifikan mengurangi jumlah parameter dan beban komputasi dibandingkan dengan konvolusi standar, tanpa mengorbankan performa secara signifikan [4].

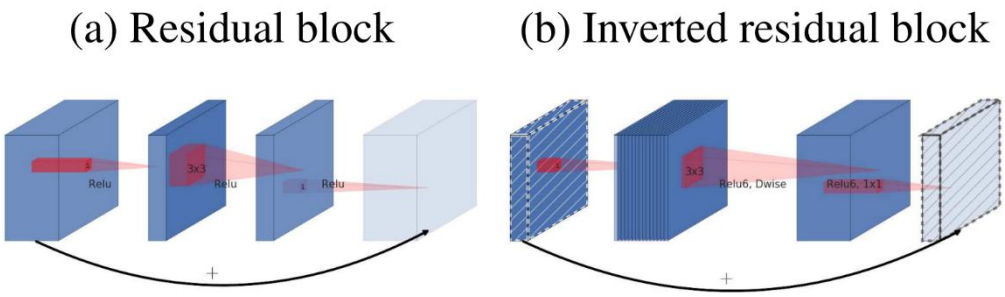
Selain itu, MobileNetV2 juga mengadopsi konsep *inverted residual block* dan *linear bottleneck*. Struktur ini memungkinkan aliran informasi yang lebih efisien di dalam jaringan dengan menjaga representasi fitur tetap kaya namun tetap

ringan secara komputasi [4], [31]. Dengan karakteristik tersebut, MobileNetV2 menjadi salah satu pilihan yang optimal dalam penelitian ini, terutama untuk menguji performa *model* yang efisien terhadap variasi kualitas citra akibat kompresi.

2.4.2 Arsitektur ResNet50

ResNet50 merupakan arsitektur CNN yang terkenal karena kemampuannya dalam membangun jaringan yang sangat dalam tanpa mengalami penurunan performa (*degradation problem*). Keunggulan utama ResNet50 terletak pada penggunaan konsep *skip connection* atau *residual connection*, yang memungkinkan input dari suatu lapisan dilewatkan langsung ke lapisan berikutnya tanpa melalui transformasi yang kompleks. Dengan adanya mekanisme ini, *model* dapat mempelajari fungsi residual (selisih antara input dan output), sehingga proses pelatihan menjadi lebih stabil dan efektif.

Struktur dasar dari ResNet50 terdiri dari *residual block* yang memungkinkan jaringan mencapai kedalaman hingga puluhan lapisan tanpa mengalami masalah *vanishing gradient*. Hal ini membuat ResNet50 mampu menangkap fitur yang lebih kompleks dan abstrak dibandingkan arsitektur yang lebih dangkal. Dalam konteks penelitian ini, ResNet50 digunakan sebagai pembanding terhadap MobileNetV2 untuk menganalisis bagaimana arsitektur yang lebih dalam dan kompleks merespons degradasi kualitas citra akibat kompresi. Dengan demikian, perbandingan kedua *model* ini diharapkan dapat memberikan gambaran yang komprehensif mengenai trade-off antara efisiensi dan kemampuan representasi fitur dalam deteksi *deepfake* [3].



Gambar 2. 1 Arsitektur MobileNetV2 dan ResNet50 [4]

Berdasarkan Gambar 2.1, terdapat perbedaan desain struktural yang fundamental. Bagian (a) merepresentasikan *Residual Block* standar yang pertama kali diperkenalkan pada arsitektur ResNet oleh [3]. Arsitektur ini menuntut beban komputasi yang besar, menggunakan *Residual Block* standar yang memiliki bentuk lebar (dimensi kanal besar) pada bagian ujung, namun menyempit (membentuk *bottleneck*) di bagian tengah. Arsitektur ini menuntut beban komputasi dan parameter yang sangat besar untuk mengekstraksi detail fitur yang dalam. Dalam konteks eksperimen penelitian ini, kedalaman arsitektur inilah yang memicu terjadinya *over-smoothing* saat model dipaksa memproses citra yang telah mengalami degradasi kompresi JPEG.

Sedangkan gambar pada bagian (b) merepresentasikan *Inverted Residual Block* yang pertama kali diperkenalkan pada arsitektur MobileNetV2 oleh [4]. Aristektur ini menggunakan inovasi *Inverted Residual Block* yang bentuknya berkebalikan; tipis di bagian ujung namun melebar di bagian tengah. Arsitektur ini mengandalkan *Depthwise Separable Convolution* (Dwise) yang sangat efisien dan membuang fungsi aktivasi non-linear di lapisan terakhirnya. Efisiensi struktural ini memungkinkan MobileNetV2 untuk berfokus pada ekstraksi fitur makro wajah, sehingga menjadikannya jauh lebih stabil dan tahan banting (*robust*) meskipun matriks piksel citra telah rusak akibat kompresi ekstrem (QF 30).

2.5 Metrik Evaluasi Kinerja *Model*

Evaluasi kinerja *model* merupakan tahap penting dalam penelitian pembelajaran mesin untuk mengukur sejauh mana *model* mampu melakukan

prediksi dengan benar. Dalam konteks klasifikasi citra wajah *real* dan *deepfake*, evaluasi tidak hanya bergantung pada tingkat akurasi, tetapi juga mempertimbangkan kemampuan *model* dalam membedakan setiap kelas secara tepat. Oleh karena itu, digunakan beberapa metrik evaluasi berbasis *confusion matrix*, yaitu akurasi (*accuracy*), presisi (*precision*), dan *recall* [32].

2.5.1 *Confusion Matrix*

Confusion matrix merupakan tabel yang digunakan untuk menggambarkan performa *model* klasifikasi dengan membandingkan antara nilai prediksi dan nilai aktual. Dalam kasus klasifikasi biner (*real* dan *deepfake*), *confusion matrix* terdiri dari empat komponen utama, yaitu:

1. *True Positive* (TP): jumlah data *deepfake* yang diprediksi dengan benar sebagai *deepfake*
2. *True Negative* (TN): jumlah data *real* yang diprediksi dengan benar sebagai *real*
3. *False Positive* (FP): jumlah data *real* yang salah diprediksi sebagai *deepfake*
4. *False Negative* (FN): jumlah data *deepfake* yang salah diprediksi sebagai *real*

Confusion matrix memberikan gambaran detail mengenai jenis kesalahan yang dilakukan oleh *model*, sehingga dapat digunakan sebagai dasar dalam perhitungan metrik evaluasi lainnya [33].

2.5.2 Akurasi (*Accuracy*)

Akurasi merupakan metrik yang mengukur proporsi jumlah prediksi yang benar terhadap keseluruhan data. Secara matematis, akurasi dirumuskan sebagai:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Akurasi memberikan gambaran umum tentang performa *model*, namun dapat menjadi kurang representatif jika distribusi data tidak seimbang (*imbalanced dataset*) [33].

2.5.3 Presisi (*Precision*)

Presisi mengukur tingkat ketepatan *model* dalam memprediksi kelas positif (*deepfake*). Metrik ini menunjukkan seberapa banyak prediksi *deepfake* yang benar-benar merupakan *deepfake*. Secara matematis, presisi dirumuskan sebagai:

$$Precision = \frac{\mathrm{TP}}{\mathrm{TP} + \mathrm{FP}}$$

Nilai presisi yang tinggi menunjukkan bahwa *model* memiliki tingkat kesalahan rendah dalam mengklasifikasikan data *real* sebagai *deepfake* [33].

2.5.4 *Recall*

Recall mengukur kemampuan *model* dalam mendeteksi seluruh data positif (*deepfake*) yang sebenarnya. Metrik ini menunjukkan seberapa banyak data *deepfake* yang berhasil terdeteksi oleh *model*. Secara matematis, recall dirumuskan sebagai:

$$Recall = \frac{\mathrm{TP}}{\mathrm{TP} + \mathrm{FN}}$$

Nilai *recall* yang tinggi menunjukkan bahwa *model* mampu mengidentifikasi sebagian besar data *deepfake*, meskipun mungkin masih menghasilkan beberapa kesalahan prediksi [33].

2.6 Ketahanan *Model* (*Robustness*) dalam Pembelajaran Mesin

Dalam konteks pembelajaran mesin (*machine learning*) dan visi komputer, ketahanan atau *robustness* merujuk pada kemampuan sebuah *model* untuk mempertahankan tingkat performa prediksinya ketika dihadapkan pada data yang memiliki gangguan (*noise*), variasi, atau transformasi yang tidak ada pada saat fase pelatihan[34]. Berbeda dengan metrik akurasi standar yang hanya mengukur ketepatan pada kondisi ideal, *robustness* mengukur stabilitas dan keandalan *model* dalam menghadapi kondisi degradasi di dunia nyata.

Pada sistem deteksi *deepfake*, *model* berbasis *Convolutional Neural Network* (CNN) sering kali sangat sensitif terhadap perubahan kecil pada tingkat piksel. Gangguan visual seperti *blur*, variasi pencahayaan, atau artefak akibat kompresi JPEG dapat merusak fitur spasial yang sebelumnya telah dipelajari oleh *model*. *Model* yang tidak *robust* akan mengalami penurunan performa (degradasi akurasi) yang sangat drastis ketika memproses citra yang telah dimanipulasi secara visual atau dikompresi [35].

Oleh karena itu, pengujian *robustness* menjadi indikator krusial sebelum sebuah arsitektur jaringan diimplementasikan. Dalam penelitian ini, *robustness*

dievaluasi secara komparatif dengan mengukur nilai selisih penurunan (*delta degradation*) dari metrik evaluasi (akurasi, presisi, dan *recall*) antara kondisi citra ideal (tidak terkompresi) dengan citra yang telah mengalami berbagai tingkatan kompresi ekstrem. *Model* dengan grafik penurunan performa yang paling landai akan disimpulkan sebagai *model* yang memiliki *robustness* tertinggi.

2.7 Penelitian Terdahulu

Tabel 2. 1 Penelitian Terdahulu

NO		KETERANGAN
1.	Judul	Deteksi *Deepfake* dalam Citra Menggunakan CNN
	Penulis & Tahun	S. A. Gulo dkk. (2025)
	Metode	*Convolutional Neural Network* (EfficientNetB0) + OpenCV Landmark
	Pembahasan	Penelitian menggunakan CNN untuk klasifikasi *deepfake* dengan bantuan ekstraksi landmark wajah menggunakan OpenCV. Proses meliputi *preprocessing*, ekstraksi fitur landmark, pelatihan *model*, serta implementasi dalam aplikasi berbasis Gradio.
	Hasil dan Kesimpulan	*Model* mencapai akurasi sebesar 91% dengan TP=1759, TN=1875, FP=241, FN=125. Sistem mampu membedakan citra *real* dan *deepfake* dengan baik, namun hanya diuji pada citra berkualitas baik dan belum mempertimbangkan variasi kualitas citra.
2.	Judul	*Deep Fake Detection using Transfer Learning: A Comparative study of Multiple Neural Networks*
	Penulis & Tahun	M. A. dkk. (2024)
	Metode	*Transfer Learning* (MobileNetV2, ResNet50, InceptionV3, EfficientNet, dll)

NO		KETERANGAN
	Pembahasan	Penelitian membandingkan beberapa *model pre-trained* untuk mendeteksi *deepfake* pada *dataset* FaceForensics++. Fokus utama pada perbandingan performa antar arsitektur dalam kondisi *dataset* ideal.
	Hasil dan Kesimpulan	MobileNetV2 memperoleh akurasi tertinggi (~89%), diikuti ResNet50 (~83%). Disimpulkan bahwa *transfer learning* efektif untuk deteksi *deepfake*, namun tidak menguji ketahanan *model* terhadap degradasi kualitas citra.
3.	Judul	*Compression-Aware Hybrid Framework for Deep Fake Detection in Low-Quality Video*
	Penulis & Tahun	L. A. Motalib (2025).
	Metode	CNN-*based Deepfake Detection*
	Pembahasan	Penelitian mengkaji pengaruh kompresi citra terhadap performa *model* deteksi *deepfake* dengan menguji berbagai tingkat kompresi (misalnya JPEG). Fokus pada perubahan kualitas citra terhadap ekstraksi fitur.
	Hasil dan Kesimpulan	Hasil menunjukkan bahwa kompresi citra menurunkan performa *model* secara signifikan karena hilangnya detail dan munculnya artefak. *Model* yang dilatih pada citra berkualitas tinggi tidak robust terhadap citra terkompresi.
4.	Judul	*An Improved Dense CNN Architecture for Deepfake Image Detection*
	Penulis & Tahun	Y. Patel dkk. (2023)
	Metode	*Convolutional Neural Network (Improved Dense CNN / D-CNN)*
	Pembahasan	Penelitian ini mengusulkan arsitektur CNN yang ditingkatkan untuk mendeteksi *deepfake* dengan

NO		KETERANGAN
		memanfaatkan beberapa *dataset* dari berbagai sumber guna meningkatkan generalisasi *model*. Proses meliputi *preprocessing* citra, pelatihan menggunakan *binary cross-entropy*, dan optimasi dengan Adam.
	Hasil dan Kesimpulan	*Model* mencapai akurasi sangat tinggi, yaitu hingga 99.33% pada beberapa *dataset* (AttGAN, GDWCT, StyleGAN, dll). Disimpulkan bahwa *model* memiliki performa tinggi dan generalisasi yang baik, namun pengujian masih terbatas pada kondisi *dataset* ideal dan tidak mempertimbangkan degradasi kualitas citra seperti kompresi.
5.	Judul	*Deepfake Image Detection Using Convolutional Neural Network*
	Penulis & Tahun	G. Morankar dkk. (2025)
	Metode	*Convolutional Neural Network* (CNN & CNN + Gabor Filter, *Transfer Learning*)
	Pembahasan	Penelitian ini menggunakan dua pendekatan, yaitu CNN standar dan CNN dengan integrasi Gabor filter untuk meningkatkan ekstraksi fitur tekstur. *Model* dilatih menggunakan *dataset* Celeb-DF dan difokuskan pada deteksi inkonsistensi wajah serta pola tekstur akibat manipulasi *deepfake*.
	Hasil dan Kesimpulan	Hasil menunjukkan bahwa CNN efektif dalam mendeteksi *deepfake*, sementara penambahan Gabor filter meningkatkan kemampuan dalam menangkap detail tekstur. Namun, penelitian ini tidak mengevaluasi performa *model* terhadap variasi kualitas citra seperti kompresi, sehingga ketahanan *model* pada kondisi dunia nyata belum teruji.

NO		KETERANGAN
6.	Judul	*Deepfake Detection using MobileNetV2 Integrated with a Support Vector Machine Classifier*
	Penulis & Tahun	B. D. Satoto dkk. (2025)
	Metode	*Convolutional Neural Network* (MobileNetV2) + *Support Vector Machine* (SVM)
	Pembahasan	Penelitian ini mengusulkan kombinasi MobileNetV2 sebagai ekstraktor fitur dan SVM sebagai *classifier* untuk mendeteksi *deepfake*. Pendekatan ini bertujuan untuk mencapai keseimbangan antara efisiensi komputasi dan akurasi, serta cocok untuk perangkat dengan sumber daya terbatas.
	Hasil dan Kesimpulan	*Model* mencapai akurasi sekitar 94–95% dengan precision 93.5% dan recall 95.6%. Pendekatan ini menunjukkan performa yang stabil pada variasi pencahayaan dan kualitas gambar, namun tidak secara spesifik mengevaluasi pengaruh tingkat kompresi citra terhadap performa *model*.
7.	Judul	*Detecting Compressed Deepfake Images Using Two-Branch Convolutional Networks with Similarity and Classifier*
	Penulis & Tahun	P. Chen dkk. (2022)
	Metode	*Convolutional Neural Network* (Two-Branch CNN / TCNSC)
	Pembahasan	Penelitian ini mengusulkan *model* dua cabang CNN yang menggabungkan pembelajaran kesamaan (*similarity learning*) dan klasifikasi untuk mendeteksi *deepfake* pada citra yang telah dikompresi dengan berbagai tingkat kualitas. *Model* dilatih menggunakan citra asli dan citra

NO		KETERANGAN
		terkompresi untuk meningkatkan ketahanan terhadap variasi kompresi.
	Hasil dan Kesimpulan	Hasil menunjukkan bahwa *model* mampu mencapai akurasi tinggi pada berbagai tingkat kompresi, yaitu 91.8% *Low Quality* (LQ), 93.4% *Medium Quality* (MQ), dan 95.3% *High Quality* (HQ), serta mengungguli metode sebelumnya secara signifikan. Penelitian ini menunjukkan pentingnya mempertimbangkan kompresi dalam deteksi *deepfake*, namun berfokus pada pengembangan arsitektur baru, bukan analisis komparatif terhadap *model* yang umum digunakan.
8.	Judul	*Celeb-DF: A Large-scale Challenging Dataset for DeepFake Forensics*
	Penulis & Tahun	Y. Li dkk. (2020)
	Metode	Evaluasi komparatif menggunakan arsitektur Convolutional Neural Network (CNN) standar (termasuk ResNet) terhadap dataset manipulasi wajah berskala besar.
	Pembahasan	Menganalisis kelemahan model deteksi *deepfake* saat ini ketika diuji menggunakan dataset Celeb-DF yang memiliki artefak manipulasi visual sangat halus dan minim dibandingkan dengan dataset generasi sebelumnya.

NO	KETERANGAN
Hasil dan Kesimpulan	Kinerja model-model standar (seperti ResNet) mengalami penurunan metrik deteksi (*Area Under Curve*/AUC) secara drastis saat diuji pada dataset ini. Celeb-DF merupakan standar pengujian yang lebih menantang, tangguh, dan realistis untuk mengukur batas ketahanan model pendeteksi *deepfake*.

Berdasarkan tabel penelitian terdahulu, dapat disimpulkan bahwa berbagai penelitian telah dilakukan dalam bidang deteksi *deepfake* berbasis citra dengan memanfaatkan metode *deep learning*, khususnya *Convolutional Neural Network* (CNN) dan pendekatan *transfer learning*. Penelitian oleh [1] serta [21] menunjukkan bahwa CNN mampu mengekstraksi fitur spasial secara efektif untuk membedakan citra asli dan *deepfake*. Selain itu, penelitian komparatif oleh [2] juga membuktikan bahwa arsitektur *pre-trained* seperti MobileNetV2 dan ResNet50 memiliki performa yang cukup tinggi dalam klasifikasi *deepfake* pada *dataset* standar. Sementara itu, [36] melalui pengembangan dataset *Celeb-DF* menunjukkan bahwa karakteristik manipulasi generasi baru memiliki detail yang jauh lebih halus, sehingga menjadi tolok ukur yang lebih menantang bagi arsitektur CNN standar.

Namun demikian, sebagian besar penelitian tersebut masih berfokus pada peningkatan akurasi *model* dalam kondisi *dataset* yang ideal, yaitu citra dengan kualitas tinggi dan minim gangguan. Hal ini menyebabkan *model* yang dihasilkan cenderung belum merepresentasikan kondisi dunia nyata, di mana citra sering mengalami degradasi kualitas akibat proses kompresi, terutama pada distribusi melalui media sosial dan platform digital.

Penelitian oleh [6] secara khusus mengkaji pengaruh kompresi citra terhadap performa *model* dan menunjukkan bahwa kompresi dapat menyebabkan penurunan akurasi secara signifikan. Temuan ini diperkuat oleh penelitian [37] yang mengusulkan arsitektur khusus untuk mendeteksi *deepfake* pada citra terkompresi, serta menunjukkan bahwa *model* konvensional memiliki keterbatasan

dalam menghadapi variasi tingkat kompresi. Meskipun demikian, penelitian tersebut lebih berfokus pada pengembangan arsitektur baru, bukan pada analisis ketahanan *model* yang telah umum digunakan.

Di sisi lain, penelitian seperti [38] dan [39] menunjukkan bahwa pengembangan arsitektur yang lebih kompleks maupun kombinasi metode seperti MobileNetV2 dan SVM mampu meningkatkan akurasi dan efisiensi komputasi. Namun, penelitian-penelitian tersebut belum mengevaluasi performa *model* secara sistematis terhadap variasi kualitas citra, khususnya akibat kompresi.

Berdasarkan identifikasi celah penelitian (*research gap*) di atas, kebaruan (novelty) pada penelitian ini terletak pada evaluasi ketahanan *model* secara sistematis tanpa harus merancang arsitektur baru dari nol, serta mengujinya pada karakteristik dataset yang lebih kompleks (*Celeb-DF v2*) setelah melalui proses penyeimbangan kelas. Penelitian ini secara spesifik akan melakukan **Analisis Ketahanan *Model Transfer Learning* MobileNetV2 dan ResNet50 terhadap Kompresi Citra pada Klasifikasi Wajah *Deepfake***. Melalui pendekatan ini, diharapkan dapat ditemukan arsitektur standar mana yang paling tangguh dan relevan untuk diimplementasikan pada kondisi nyata pendistribusian citra digital.

2.8 Kerangka Berpikir

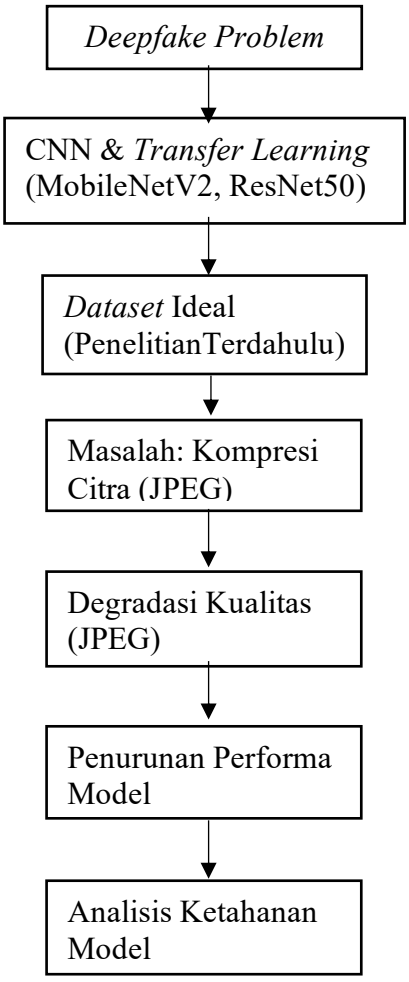
Perkembangan teknologi *deep learning* telah mendorong peningkatan kemampuan sistem dalam mendeteksi citra *deepfake* dengan akurasi yang tinggi, khususnya melalui pemanfaatan *Convolutional Neural Network* (CNN) dan pendekatan *transfer learning*. Berbagai penelitian menunjukkan bahwa arsitektur seperti MobileNetV2 dan ResNet50 mampu mengekstraksi fitur spasial secara efektif untuk membedakan citra asli dan citra manipulasi.

Namun, sebagian besar penelitian tersebut dilakukan pada *dataset* dengan kualitas citra yang tinggi dan kondisi yang terkontrol, sehingga belum sepenuhnya merepresentasikan kondisi dunia nyata. Dalam praktiknya, citra yang beredar di media digital umumnya telah mengalami proses kompresi, seperti JPEG, yang dapat menyebabkan hilangnya detail spasial serta munculnya artefak pada citra.

Degradasi kualitas citra akibat kompresi berpotensi memengaruhi kemampuan *model* dalam mengekstraksi fitur penting yang digunakan untuk

klasifikasi *deepfake*. Beberapa penelitian menunjukkan bahwa performa *model* dapat menurun secara signifikan ketika dihadapkan pada citra terkompresi, sementara sebagian lainnya menunjukkan dampak yang bervariasi tergantung pada metode dan domain data yang digunakan.

Berdasarkan kondisi tersebut, diperlukan suatu analisis yang mengkaji ketahanan *model transfer learning* terhadap variasi kualitas citra akibat kompresi. Oleh karena itu, penelitian ini berfokus pada evaluasi performa arsitektur MobileNetV2 dan ResNet50 dalam mengklasifikasikan citra *deepfake* pada berbagai tingkat kompresi, serta mengujinya pada karakteristik dataset yang lebih kompleks (*Celeb-DF v2*) setelah melalui proses penyeimbangan kelas. Pengujian ini dilakukan guna mengetahui sejauh mana *model* tersebut dapat diandalkan dalam kondisi dunia nyata.

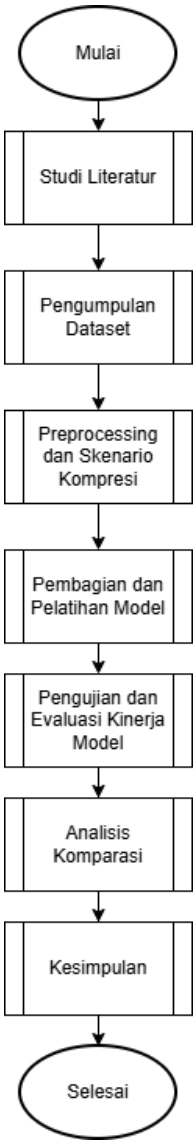


Gambar 2. 2 Kerangka Berpikir

BAB III
METODOLOGI PENELITIAN

3.1 Tahapan Penelitian

Penelitian ini dilaksanakan melalui beberapa tahapan sistematis untuk menganalisis ketahanan *model deep learning* terhadap degradasi kualitas citra akibat kompresi. Setiap tahapan dirancang untuk memastikan proses eksperimen berjalan terstruktur dan menghasilkan evaluasi yang objektif. Adapun tahapan penelitian yang dilakukan adalah sebagai berikut:



Gambar 3. 1 Tahapan Penelitian

1. Studi Literatur

Tahap awal dilakukan dengan mengkaji berbagai literatur ilmiah yang berkaitan dengan deteksi *deepfake*, khususnya penggunaan *Convolutional Neural Network* (CNN) dan pendekatan *transfer learning*. Selain itu, dilakukan identifikasi terhadap kelemahan *model* pada kondisi dunia nyata, khususnya terkait degradasi kualitas citra akibat kompresi. Hasil studi literatur digunakan untuk merumuskan permasalahan dan tujuan penelitian.

2. Pengumpulan *Dataset*

Pada tahap ini dilakukan pengumpulan *dataset* citra wajah yang terdiri dari dua kelas, yaitu citra asli (*real*) dan citra manipulasi (*deepfake*). *Dataset* diperoleh dari sumber publik seperti *Celeb-DF v2*, yang telah banyak digunakan dalam penelitian deteksi *deepfake* sehingga memiliki kredibilitas yang tinggi.

3. *Preprocessing* dan Skenario Kompresi

Sebelum diumpankan ke dalam model, citra mentah harus dipersiapkan melalui penyesuaian dimensi dan penyeimbangan jumlah distribusi kelas. Setelah itu, data akan disimulasikan ke dalam berbagai tingkat kompresi untuk menciptakan skenario pengujian degradasi kualitas citra.

4. Pembagian dan Pelatihan *Model*

Dataset yang telah siap pakai dibagi menjadi dua bagian, yaitu untuk pelatihan dan pengujian. Bagian data latih kemudian digunakan untuk melatih arsitektur MobileNetV2 dan ResNet50 agar kedua model tersebut mampu mengenali pola yang membedakan wajah asli dan *deepfake*.

5. Pengujian dan Evaluasi Kinerja *Model*

Arsitektur model yang telah selesai dilatih kemudian diuji menggunakan bagian data uji pada berbagai skenario tingkat kompresi. Kinerja model dalam menebak citra kemudian diukur secara kuantitatif menggunakan metrik evaluasi yang telah ditentukan.

6. Analisis Komparasi

Tahap ini merupakan inti dari penelitian, di mana dilakukan analisis perbandingan terhadap ketahanan (*robustness*) *model* MobileNetV2 dan ResNet50. Analisis difokuskan pada sejauh mana performa *model* mengalami penurunan

ketika dihadapkan pada citra terkompresi, sehingga dapat diketahui *model* mana yang lebih stabil dalam kondisi kualitas citra yang bervariasi.

7. Kesimpulan

Tahap akhir adalah penarikan kesimpulan berdasarkan hasil eksperimen yang telah dilakukan. Kesimpulan disusun untuk menjawab rumusan masalah serta memberikan rekomendasi terkait *model* yang memiliki ketahanan terbaik terhadap kompresi citra dalam deteksi *deepfake*.

3.2 Objek Penelitian

Objek penelitian dalam studi ini adalah citra wajah yang diklasifikasikan ke dalam dua kategori, yaitu citra asli (*real*) dan citra manipulasi (*deepfake*). Data yang digunakan dalam penelitian ini bersumber dari *dataset* publik yang telah banyak digunakan dalam penelitian deteksi *deepfake*, sehingga memiliki tingkat validitas dan reliabilitas yang tinggi.

Dataset yang digunakan adalah *Celeb-DF v2*, yang merupakan salah satu *dataset* standar dalam penelitian *deepfake detection* [36]. *Dataset* ini terdiri dari berbagai citra dan video wajah yang telah dimanipulasi menggunakan beberapa metode *face manipulation*. Dalam penelitian ini, data yang digunakan difokuskan pada citra wajah yang diekstraksi dari *dataset* tersebut.

Setiap citra dalam *dataset* memiliki label yang menunjukkan apakah citra tersebut termasuk dalam kategori *real* atau *deepfake*. Data ini digunakan untuk melatih dan menguji *model* dalam melakukan klasifikasi. Selain itu, *dataset* ini juga menyediakan variasi kualitas citra, sehingga memungkinkan dilakukannya simulasi kompresi untuk menguji ketahanan *model* terhadap degradasi kualitas citra.

Pemilihan *dataset Celeb-DF v2* didasarkan pada beberapa pertimbangan, antara lain: (1) *dataset* ini telah digunakan secara luas dalam penelitian sebelumnya sehingga memudahkan proses validasi hasil penelitian, (2) memiliki jumlah data yang cukup besar untuk melatih *model deep learning*, dan (3) Pemilihan dataset Celeb-DF v2 didasarkan pada kualitas manipulasi visual wajah yang sangat halus dan realistis, yang lebih merepresentasikan kondisi penyebaran deepfake di dunia nyata dibandingkan dataset generasi sebelumnya.[21].

3.3 Jadwal Penelitian

Jadwal penelitian merupakan rencana waktu pelaksanaan setiap tahapan penelitian yang dilakukan secara sistematis. Penyusunan jadwal ini bertujuan untuk memastikan bahwa seluruh proses penelitian dapat diselesaikan sesuai dengan waktu yang telah ditentukan. Kegiatan penelitian meliputi studi literatur, pengumpulan data, pengolahan data, pelatihan *model*, pengujian, analisis hasil, hingga penyusunan laporan skripsi.

Adapun jadwal pelaksanaan penelitian dapat dilihat pada Tabel 3.1 berikut.

Tabel 3. 1 Jadwal Penelitian

Kegiatan	Februari	Maret	April	Mei	Juni	Juli
Studi Literatur						
Pengumpulan *Dataset*						
Preprocessing & Kompresi Citra						
Pelatihan *Model* (*training*)						
Pengujian *Model* (*testing*)						
Evaluasi & Analisis						
Penyusunan Laporan Skripsi						

3.4 Metode Penelitian

Bagian ini menguraikan seluruh langkah teknis, skenario, dan pendekatan yang digunakan untuk menjawab rumusan masalah dalam penelitian. Rincian metode penelitian ini mencakup penyiapan *dataset*, skenario *preprocessing* dan kompresi citra, penentuan arsitektur *transfer learning*, hingga metrik evaluasi yang digunakan untuk analisis komparasi, yang dijabarkan pada sub-bab berikut:

3.4.1 Jenis Penelitian

Jenis penelitian yang digunakan dalam skripsi ini adalah penelitian eksperimental kuantitatif (*quantitative experimental research*). Pendekatan kuantitatif dipilih karena penelitian ini mengukur fenomena secara objektif menggunakan angka dan statistik, yaitu mengevaluasi metrik performa *model*

(akurasi, presisi, dan *recall*). Sementara itu, sifat eksperimental diterapkan karena penelitian ini melakukan manipulasi atau perlakuan (*treatment*) secara sengaja terhadap objek penelitian yaitu memberikan variasi tingkat kompresi pada citra input untuk mengamati dan menganalisis dampak dari perlakuan tersebut terhadap ketahanan (*robustness*) arsitektur *model* klasifikasi *deepfake* [40].

3.4.3 *Dataset*

Data utama yang digunakan sebagai objek dalam penelitian ini adalah citra wajah digital yang terbagi menjadi dua representasi kelas, yaitu citra asli (*real*) dan citra manipulasi (*deepfake*). Dataset ini bersumber dari Celeb-DF v2 yang disediakan melalui platform Kaggle, secara spesifik menggunakan subset citra wajah statis yang telah dipotong (*pre-cropped faces*). Secara keseluruhan, data mentah pada dataset ini memiliki total 80.824 citra, yang terdiri dari 40.536 citra pada kelas *Deepfake* dan 40.288 citra pada kelas *Real*. Data mentah ini selanjutnya akan melalui tahap pra-pemrosesan untuk memastikan keseimbangan dan kesesuaian format sebelum diumpankan ke dalam model [36].

3.4.4 *Preprocessing* Data

Proses *preprocessing* merupakan tahapan krusial untuk mempersiapkan citra mentah sebelum diekstraksi fiturnya oleh model klasifikasi. Karena dataset yang digunakan telah berupa subset citra wajah yang terekstraksi (*cropped faces*), tahapan ini akan difokuskan pada tiga prosedur utama, yaitu:

1. Normalisasi Dimensi (*Resizing*): Seluruh citra wajah statis akan diubah ukurannya (*resize*) secara seragam menjadi matriks berdimensi 224 x 224 piksel. Hal ini wajib dilakukan guna memenuhi syarat dimensi standar input pada arsitektur MobileNetV2 dan ResNet50.
2. Penyeimbangan Kelas (Random Undersampling): Data mentah Celeb-DF v2 memiliki ketimpangan distribusi kelas (*class imbalance*), di mana jumlah kelas *Deepfake* lebih banyak daripada kelas *Real*. Untuk mencegah model mengalami bias mayoritas selama pelatihan, teknik *Random Undersampling* akan diterapkan. Teknik ini bekerja dengan cara mereduksi secara acak jumlah citra

pada kelas mayoritas (*Deepfake*) agar seimbang sempurna dengan jumlah citra pada kelas minoritas (*Real*), sehingga rasio akhir data menjadi 1:1.

3. Pembagian Data (Data Splitting**):** Setelah dataset seimbang, seluruh citra akan dipisah menggunakan rasio standar industri yaitu 80:20. Sebanyak 80% dari total data akan dialokasikan sebagai data latih (*training set*) untuk proses pembelajaran model, dan 20% sisanya akan diisolasi murni sebagai data uji (*testing set*) untuk mengukur performa model pada tahap evaluasi [18].

3.4.5 Skenario Kompresi Citra

Untuk mengukur tingkat ketahanan (*robustness*) *model* terhadap kondisi distribusi citra di dunia nyata, data uji (*testing set*) akan disimulasikan ke dalam beberapa tingkat degradasi menggunakan algoritma kompresi berformat JPEG. Perlakuan kompresi ini dibagi ke dalam empat skenario *Quality Factor* (QF), yaitu:

1. Kondisi Ideal (Original): Citra wajah dipertahankan pada resolusi dan kualitas aslinya tanpa kompresi tambahan. Skenario ini digunakan sebagai *baseline* (tolok ukur dasar) untuk mengetahui performa maksimal *model*.
2. Kompresi Ringan (QF 90): Simulasi kompresi tingkat rendah di mana pengurangan informasi spasial sangat minim dan artefak kompresi hampir tidak kasat mata.
3. Kompresi Sedang (QF 60): Simulasi kompresi tingkat menengah yang merepresentasikan degradasi visual standar ketika sebuah citra didistribusikan melalui platform media sosial atau aplikasi perpesanan instan.
4. Kompresi Ekstrem (QF 30): Simulasi kompresi tingkat tinggi yang secara sengaja merusak struktur piksel dan menghasilkan artefak visual yang signifikan (*blocking* dan *blur*). Skenario ini bertujuan untuk mengukur titik kritis ketahanan *model*.

3.4.6 Arsitektur *Model*

Penelitian ini menggunakan pendekatan *Transfer Learning* untuk mengklasifikasikan citra ke dalam dua kelas biner (*Real* dan *Deepfake*). Arsitektur yang digunakan adalah MobileNetV2 dan ResNet50 yang telah dilatih sebelumnya (*pre-trained*) menggunakan *dataset* berskala besar, yaitu ImageNet [4]. Karena kedua arsitektur ini aslinya dirancang untuk mendeteksi ribuan kelas objek,

dilakukan modifikasi pada lapisan akhir jaringan (*classifier head*). Lapisan *Fully Connected* (klasifikasi bawaan) pada kedua *model* dihapus dan diganti dengan arsitektur lapisan klasifikasi baru yang terdiri dari lapisan *Global Average Pooling*, diikuti oleh lapisan *Dense* dengan fungsi aktivasi *Sigmoid* atau *Softmax* untuk menghasilkan probabilitas prediksi biner. Lapisan dasar (*base layers*) dari kedua *model* difungsikan sebagai ekstraktor fitur spasial, di mana bobot (*weights*) pada sebagian lapisan tersebut dibekukan (*frozen*) untuk mempertahankan pengetahuan dasar, sementara lapisan akhir dilatih ulang (*fine-tuning*) menggunakan *dataset* wajah yang telah disiapkan.

3.4.7 Proses Pelatihan dan Pengujian

Proses eksperimen dibagi menjadi dua fase utama, yaitu fase pelatihan (*training*) dan fase pengujian (*testing*):

1. **Fase Pelatihan:** Model MobileNetV2 dan ResNet50 dilatih menggunakan data latih dari kondisi ideal. Proses pelatihan dikonfigurasi menggunakan algoritma optimasi Adam (*Adam Optimizer*) dengan tingkat pembelajaran (*learning rate*) sebesar 1e-5 untuk memperbarui bobot jaringan secara berkala, serta menggunakan fungsi kerugian *Binary Cross-Entropy* untuk mengevaluasi selisih antara nilai prediksi biner dan nilai aktual secara kuantitatif [41]. Pelatihan ini dijadwalkan berjalan dalam beberapa iterasi *batch* yang terstruktur dengan batas maksimal hingga 50 *epoch*. Demi menghindari fenomena *overfitting* (kondisi di mana model terlalu menghafal data latih namun gagal menggeneralisasi data baru) serta untuk efisiensi waktu komputasi, fase pelatihan ini mengintegrasikan mekanisme *Early Stopping* yang memantau pergerakan nilai kerugian validasi (*validation loss*). Apabila nilai *validation loss* tidak menunjukkan penurunan atau justru mengalami pembengkakan selama 10 *epoch* berturut-turut (*patience* = 10), proses pelatihan akan dihentikan secara otomatis oleh sistem, dan bobot terbaik yang menghasilkan *loss* terendah akan dikembalikan serta disimpan (*restore best weights*) sebagai hasil akhir tingkat konvergensi model.
2. **Fase Pengujian:** Setelah kedua arsitektur model berhasil menyelesaikan fase pelatihan dan menyimpan konfigurasi bobot terbaiknya, model-model tersebut

memasuki fase pengujian. Pada fase ini, performa model dievaluasi secara independen menggunakan data uji (*testing set*) yang telah diisolasi murni dan disimulasikan ke dalam 4 skenario tingkat kompresi citra JPEG, yaitu kondisi asli (*Original* atau QF 100), kompresi ringan (QF 90), kompresi sedang (QF 60), dan kompresi ekstrem (QF 30). Model sepenuhnya dilarang melakukan pembaruan bobot atau pembelajaran ulang pada fase ini, dan hanya bertugas mengeksekusi fungsi prediksi murni terhadap citra terkompresi untuk menghasilkan nilai metrik evaluasi yang objektif.

3.4.8 Evaluasi Kinerja *Model*

Kinerja dari kedua arsitektur *model* dievaluasi secara kuantitatif menggunakan matriks kebingungan (*Confusion Matrix*). Dalam konteks pendeteksian manipulasi, citra *Deepfake* dikategorikan sebagai kelas Positif, sedangkan citra *Real* dikategorikan sebagai kelas Negatif. Terdapat empat nilai dasar yang dihasilkan [33]:

1. True Positive (TP): Jumlah citra *Deepfake* yang diprediksi benar sebagai *Deepfake*.
2. True Negative (TN): Jumlah citra *Real* yang diprediksi benar sebagai *Real*.
3. False Positive (FP): Jumlah citra *Real* yang salah diprediksi sebagai *Deepfake*.
4. False Negative (FN): Jumlah citra *Deepfake* yang salah diprediksi sebagai *Real*.

Berdasarkan nilai dasar tersebut, kinerja *model* dihitung menggunakan tiga metrik utama:

1. Akurasi (*Accuracy*)

Mengukur persentase ketepatan *model* dalam memprediksi keseluruhan data uji secara benar. Secara matematis, akurasi dirumuskan sebagai:

$$Accuracy = \frac{\mathrm{TP} + \mathrm{TN}}{\mathrm{TP} + \mathrm{TN} + \mathrm{FP} + \mathrm{FN}}$$

2. Presisi (*Precision*)

Mengukur tingkat ketepatan prediksi kelas positif, yaitu persentase citra yang benar-benar *Deepfake* dari seluruh citra yang diprediksi *model* sebagai *Deepfake*. Secara matematis, presisi dirumuskan sebagai:

$$Precision = \frac{\mathrm{TP}}{\mathrm{TP} + \mathrm{FP}}$$

3. Recall

Mengukur kemampuan *model* dalam menemukan kembali seluruh data kelas positif, yaitu persentase citra *Deepfake* yang berhasil ditebak dari seluruh total citra *Deepfake* yang ada.

$$Recall = \frac{\mathrm{TP}}{\mathrm{TP} + \mathrm{FN}}$$

3.4.9 Analisis Komparasi *Model*

Tahap ini adalah muara dari seluruh rangkaian metodologi. Hasil evaluasi (Akurasi, Presisi, dan Recall) dari MobileNetV2 dan ResNet50 tidak hanya dicatat untuk kondisi ideal, tetapi diplot dan dibandingkan tingkat penurunannya secara linier di setiap skenario kompresi (QF 90, QF 60, QF 30). Analisis komparasi dilakukan untuk mencari *model* mana yang memiliki delta penurunan performa paling landai (paling stabil). Kesimpulan analisis ini akan menghasilkan sebuah evaluasi *trade-off* (keseimbangan) yang merekomendasikan arsitektur mana yang secara praktis paling tangguh (*robust*) dan layak untuk diimplementasikan dalam menghadapi distribusi citra berkualitas rendah di dunia nyata.

BAB IV
HASIL DAN PEMBAHASAN

4.1 Pengumpulan Data

Penelitian ini menggunakan dataset Celeb-DF v2 sebagai data latih dan data uji untuk model pendeteksi *deepfake*. Pemilihan dataset ini didasarkan pada kualitas manipulasi visual wajah yang sangat halus dan realistis jika dibandingkan dengan dataset generasi sebelumnya. Citra manipulasi pada Celeb-DF v2 memiliki tingkat realisme yang menyerupai kondisi penyebaran informasi di dunia nyata, dengan meminimalisasi jejak artefak manipulasi yang mencolok. Menurut Penelitian [36] karakteristik tingkat realisme yang tinggi ini menjadikannya sebagai standar pengujian yang sangat ideal, menantang, dan realistis untuk mengukur batas ketahanan (*robustness*) arsitektur *Convolutional Neural Network* (CNN). Lebih lanjut, ketahanan ekstraksi fitur CNN ini menjadi sangat krusial untuk diuji ketika dihadapkan pada skenario degradasi kualitas di dunia nyata seperti kompresi JPEG, yang menurut temuan [6] dan [37] terbukti mampu mendistorsi informasi visual dan menurunkan performa model klasifikasi secara signifikan.

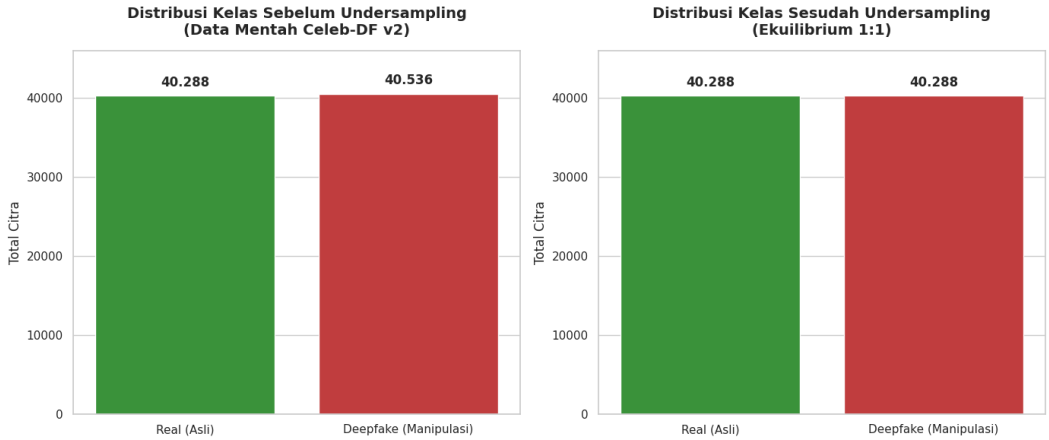
Berdasarkan hasil ekstraksi data mentah dari sumber publik, diperoleh total 80.824 citra wajah statis (*pre-cropped faces*). Distribusi data awal tersebut terdiri dari 40.288 citra pada kelas *Real* (Asli) dan 40.536 citra pada kelas *Deepfake* (Manipulasi). Kumpulan data mentah inilah yang menjadi objek material untuk dieksekusi pada tahapan pra-pemrosesan.

4.2 Pra-Pemrosesan dan Penyeimbangan Kelas

Berdasarkan hasil pengumpulan data mentah, teridentifikasi adanya ketimpangan distribusi kelas (*class imbalance*), di mana jumlah citra *Deepfake* lebih mendominasi. Untuk mencegah model kecerdasan buatan mengalami bias mayoritas (kecenderungan memprediksi kelas *Deepfake* secara sepihak), teknik *Random Undersampling* diterapkan.

Teknik ini dilakukan secara sistematis dengan menghitung batas maksimal citra pada kelas minoritas (*Real*), kemudian melakukan pengambilan sampel secara acak (*random sampling*) pada kelas mayoritas (*Deepfake*) sesuai dengan batas

maksimal tersebut. Melalui proses *undersampling* ini, diperoleh distribusi data akhir yang seimbang sempurna dengan rasio 1:1. Jumlah citra *Deepfake* berhasil direduksi dari 40.536 menjadi 40.288 citra, sehingga menghasilkan total dataset sebanyak 80.576 citra siap pakai. Perbandingan visualisasi distribusi data sebelum dan sesudah penyeimbangan dapat dilihat pada Gambar 4.1.



Gambar 4. 1 Grafik Distribusi Sebelum dan Sesudah *Undersampling*

Melalui proses *undersampling* ini, diperoleh distribusi data akhir yang seimbang sempurna dengan rasio 1:1. Dari total keseluruhan data seimbang tersebut, 20% diisolasi murni sebagai data pengujian (*testing set*), yaitu sebanyak 8.057 citra untuk kelas *Real* dan 8.057 citra untuk kelas *Deepfake* (total 16.114 citra pengujian). Ekuilibrium distribusi data uji ini secara efektif memaksa arsitektur MobileNetV2 dan ResNet50 untuk memprediksi citra secara objektif dan adil, sehingga metrik evaluasi yang dihasilkan nantinya benar-benar merepresentasikan kecerdasan model yang murni.

4.3 Skenario Pengujian

Untuk menguji tingkat ketahanan (*robustness*) model secara komparatif dan sistematis, data uji (*testing set*) yang telah diisolasi disimulasikan ke dalam empat skenario degradasi kualitas menggunakan algoritma kompresi JPEG. Pembagian skenario ini dirancang untuk meniru karakteristik penyebaran citra digital di dunia nyata, sebagaimana yang ditunjukkan pada Gambar 4.2.



Gambar 4. 2 Kualitas Citra Wajah pada Berbagai Tingkat Kompresi JPEG

Pembagian skenario ini dirancang untuk meniru karakteristik penyebaran citra digital di dunia nyata, yang dijabarkan sebagai berikut:

1. Skenario *Quality Factor* (QF) 100 (Kondisi Ideal): Citra wajah diuji pada kualitas aslinya tanpa modifikasi atau kompresi tambahan. Skenario ini berfungsi sebagai *baseline* (tolok ukur dasar) untuk mengukur performa puncak kedua model sebelum dihadapkan pada gangguan piksel.
2. Skenario *Quality Factor* (QF) 90 (Kompresi Ringan): Citra mengalami reduksi informasi spasial tingkat rendah. Pada kondisi ini, penurunan kualitas piksel sangat minim dan artefak kompresi hampir tidak dapat diidentifikasi oleh penglihatan manusia secara langsung.
3. Skenario *Quality Factor* (QF) 60 (Kompresi Menengah): Citra dikompresi pada tingkat moderat untuk mensimulasikan standar kompresi otomatis yang terjadi ketika sebuah berkas media didistribusikan melalui platform media sosial atau aplikasi perpesanan instan (seperti WhatsApp, Telegram, atau Instagram).
4. Skenario *Quality Factor* (QF) 30 (Kompresi Ekstrem): Citra dirusak secara agresif hingga memunculkan artefak visual yang sangat jelas berupa efek keburaman (*blurring*) dan distorsi kotak (*blocking artifact*). Skenario ini bertujuan untuk menguji titik kritis ketahanan ekstraksi fitur dari kedua arsitektur model.

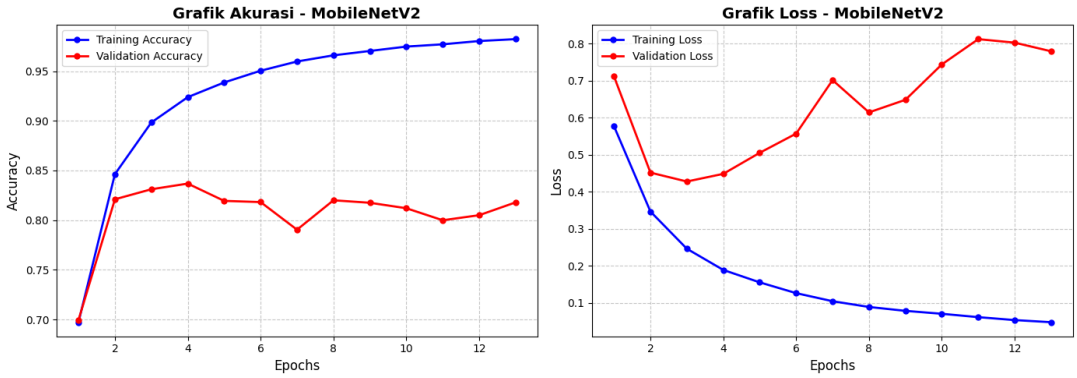
4.4 Hasil Pelatihan Model

Proses pelatihan untuk kedua arsitektur model *transfer learning* dilakukan menggunakan lingkungan komputasi yang serasi guna menjamin keadilan pengujian. Rekam jejak performa adaptasi model selama fase pembelajaran ini dicatat berdasarkan pergerakan nilai akurasi dan fungsi kerugian (*loss*) pada data

latih maupun data validasi di setiap *epoch*. Visualisasi riwayat pelatihan ini digunakan untuk mendeteksi tingkat konvergensi serta potensi terjadinya fenomena *overfitting*.

4.4.1 Proses Pelatihan *MobileNetV2*

Arsitektur MobileNetV2 dilatih dengan batas maksimum 50 *epoch* dan dikombinasikan bersama fitur penghentian otomatis (*Early Stopping*). Berdasarkan visualisasi data yang terekam, jalannya proses pembelajaran model ini disajikan secara mendetail pada Gambar 4.1 berikut.



Gambar 4. 3 Grafik Akurasi *MobileNetV2*

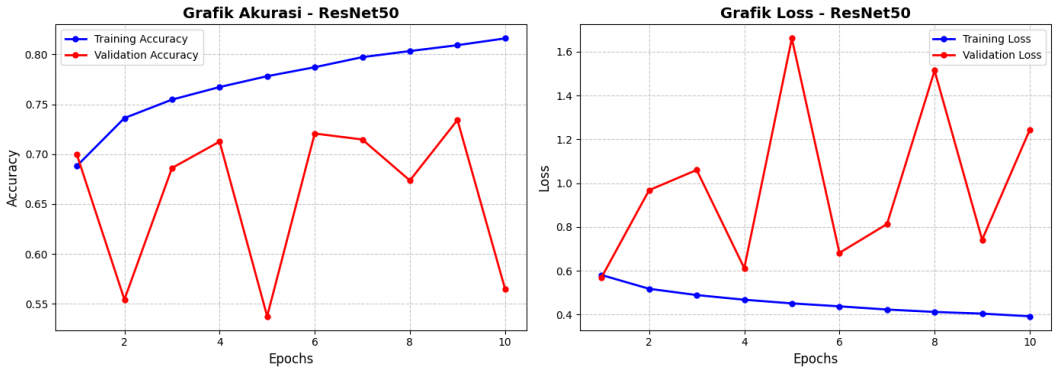
Berdasarkan Gambar 4.1, arsitektur MobileNetV2 menunjukkan grafik pembelajaran yang sangat progresif pada awal *epoch*. Akurasi data latih (*training accuracy*) melesat tajam dari 69,73% pada *epoch* pertama menjadi 84,63% pada *epoch* kedua, yang dibarengi dengan penurunan nilai *loss* secara konsisten. Nilai keraguan pada data validasi (*validation loss*) menyentuh titik paling optimal (terendah) pada *epoch* ketiga yaitu sebesar 0,4274 dengan tingkat akurasi validasi berada di angka 83,11%.

Namun, setelah melewati *epoch* ketiga, grafik mulai menunjukkan gejala *overfitting* yang umum terjadi pada model adaptasi. Garis *training accuracy* terus merangkak naik hingga mendekati sempurna di angka 98,22% pada *epoch* ke-13 dengan nilai *training loss* yang semakin mengecil ke 0,0478. Sebaliknya, garis *validation loss* justru berbalik arah dan naik secara gradual hingga menyentuh angka 0,7788 pada *epoch* ke-13. Kondisi divergen ini mengindikasikan bahwa model mulai menghafal pola piksel data latih secara spesifik namun kehilangan

kemampuan generalisasi pada data baru. Guna mengamankan performa terbaik, mekanisme *Early Stopping* yang memantau parameter *patience* selama 10 *epoch* berturut-turut berhasil memotong paksa jalannya pelatihan pada *epoch* ke-13, serta mengembalikan bobot kecerdasan model ke konfigurasi terbaiknya pada *epoch* ketiga untuk dipakai pada pengujian final.

4.4.2 Proses Pelatihan ResNet50

Pelatihan model pembanding ResNet50 dikonfigurasi dengan parameter yang identik dengan model pertama. Pergerakan parameter akurasi dan fungsi kerugian dari arsitektur yang memiliki lapisan residual dalam ini disajikan secara lengkap pada Gambar 4.2 berikut.



Gambar 4. 4 Grafik Akurasi ResNet50

Berdasarkan grafik pada Gambar 4.2, ResNet50 menunjukkan karakteristik pelatihan yang sangat kontras dan tidak stabil dibandingkan MobileNetV2. Meskipun nilai akurasi latih dan *loss* latih bergerak membaik secara konsisten di setiap *epoch*, garis evaluasi pada data validasi menunjukkan pola fluktuasi yang sangat ekstrem menyerupai bentuk gergaji. Pada *epoch* ke-4, model sempat mencapai titik efisiensi terbaik dengan nilai *validation loss* sebesar 0,6119 dan akurasi validasi 71,26%. Namun, tepat pada *epoch* berikutnya (*epoch* 5), nilai *validation loss* meledak secara drastis ke angka 1,6609 dan akurasi validasi merosot tajam ke titik 53,74%.

Pola naik-turun yang agresif ini terulang kembali pada *epoch-epoch* selanjutnya. Fenomena ini membuktikan adanya ketidakstabilan sistemis (*gradient instability*) di dalam jaringan residual ResNet50 yang terlalu dalam ketika dipaksa

mengekstraksi fitur manipulasi visual halus pada dataset Celeb-DF v2. Karena tidak mendeteksi adanya tren perbaikan yang stabil dari batas optimal *epoch* ke-4, fungsi *Early Stopping* menghentikan total proses pelatihan ini pada *epoch* ke-10 demi menghindari kerusakan bobot parameter yang lebih parah.

4.5 Hasil Evaluasi dan Komparasi Model

Setelah menyelesaikan fase pelatihan dan mengunci bobot terbaik dari masing-masing arsitektur, kedua model diuji secara mandiri menggunakan data uji (*testing set*) yang telah diisolasi sebelumnya. Pengujian ini dilakukan secara terstruktur melintasi empat skenario tingkat kompresi JPEG, yaitu *Quality Factor* (QF) 100, 90, 60, dan 30. Hasil pengujian ini dicatat secara kuantitatif berdasarkan metrik evaluasi kuantitatif yang meliputi tingkat akurasi keseluruhan (*accuracy*), presisi (*precision*), sensitivitas (*recall*), serta *F1-score* untuk masing-masing kelas (Real dan Deepfake). Rekam jejak performa komparatif dari MobileNetV2 dan ResNet50 dalam mendeteksi citra manipulasi wajah disajikan secara komprehensif pada Tabel 4.1 berikut.

Tabel 4. 1 Metrik Komparasi Performa Model terhadap Hasil Kompresi Citra

Arsitektur Model	**Skenario Kompresi**	**Kelas Citra**	**Presisi (Precision)**	**Sensitivitas (Recall)**	**F1-Score**	**Akurasi (Accuracy)**
MobileNetV2	QF 100 *(Original)*	Deepfake Real	0.82 0.84	0.85 0.81	0.83 0.83	83%
	QF 90 *(Ringan)*	Deepfake Real	0.82 0.84	0.85 0.81	0.83 0.82	83%
	QF 60 *(Sedang)*	Deepfake Real	0.81 0.83	0.83 0.81	0.82 0.82	82%
	QF 30 *(Ekstrem)*	Deepfake Real	0.80 0.81	0.82 0.80	0.81 0.80	81%
ResNet50	QF 100 *(Original)*	Deepfake Real	0.64 0.86	0.92 0.48	0.75 0.61	70%
	QF 90 *(Ringan)*	Deepfake Real	0.64 0.86	0.92 0.48	0.76 0.62	70%
	QF 60 *(Sedang)*	Deepfake Real	0.64 0.87	0.93 0.47	0.76 0.61	70%
	QF 30 *(Ekstrem)*	Deepfake Real	0.64 0.87	0.93 0.47	0.76 0.61	70%

4.6 Analisis dan Pembahasan

Data kuantitatif yang diperoleh dari tahap pengujian memberikan pemahaman mendalam mengenai karakteristik operasional dari masing-masing arsitektur *transfer learning* ketika dihadapkan pada tantangan kompresi citra. Analisis dilakukan secara komparatif untuk membedah korelasi antara penurunan kualitas piksel akibat algoritma JPEG dengan stabilitas performa model dalam mempertahankan akurasi deteksi biner. Pembahasan hasil evaluasi ini dibagi ke dalam beberapa poin analisis utama guna menjawab rumusan masalah penelitian secara ilmiah dan objektif.

4.6.1 Dampak Kompresi JPEG Terhadap Ketahanan Deteksi

Berdasarkan data eksperimen pada Tabel 4.1, kompresi citra berbasis JPEG terbukti memberikan pengaruh yang bervariasi terhadap tingkat ketahanan (*robustness*) model. Pada arsitektur MobileNetV2, terlihat adanya tren penurunan akurasi yang bersifat gradual seiring dengan semakin tingginya tingkat kompresi (penurunan nilai QF). Ketika model memproses citra ideal (QF 100), akurasi yang dicapai adalah 83%. Nilai ini bertahan stabil pada kompresi ringan (QF 90), namun mulai mengalami degradasi sebesar 1% pada kompresi menengah (QF 60) menjadi 82%, dan kembali turun ke titik terendah 81% pada kompresi ekstrem (QF 30). Penurunan total yang hanya sebesar 2% ini membuktikan bahwa hilangnya detail spasial pada komponen frekuensi tinggi akibat kuantisasi JPEG merusak artefak halus khas *deepfake*, namun MobileNetV2 teruji sangat *robust* karena mampu mempertahankan kinerja di atas 80% pada kondisi visual terburuk.

Sementara itu, kompresi JPEG secara unik tidak mengubah nilai akurasi ResNet50 yang konstan berada di angka 70% melintasi seluruh skenario QF 100 hingga QF 30. Fenomena stagnasi ini mengindikasikan bahwa ResNet50 telah mencapai batas bawah pemahamannya (*performance floor*) sejak kondisi ideal. Distorsi piksel tambahan akibat tingkat kompresi menengah maupun ekstrem tidak lagi memengaruhi kebingungan model, karena arsitektur tersebut sudah gagal menangkap parameter pembeda yang konsisten sejak citra berada pada kualitas terbaiknya.

4.6.2 Analisis Karakteristik Klasifikasi dan Perilaku Model

Perbandingan metrik secara mendetail mengungkap perbedaan perilaku yang kontras antara kedua arsitektur dalam mengklasifikasikan wajah asli dan manipulasi. MobileNetV2 menunjukkan performa yang sangat seimbang (*well-balanced*) dan objektif. Hal ini tecermin dari nilai *F1-score* kelas *Deepfake* (0.83) dan kelas *Real* (0.83) pada QF 100 yang setara, serta nilai presisi kelas *Real* yang mencapai 0.84. Angka ini membuktikan bahwa penerapan teknik *Random Undersampling* pada tahap pra-pemrosesan berhasil melenyapkan bias mayoritas secara tuntas, sehingga MobileNetV2 dapat mengenali kedua karakteristik kelas secara adil tanpa menganaktirikan kelas citra asli.

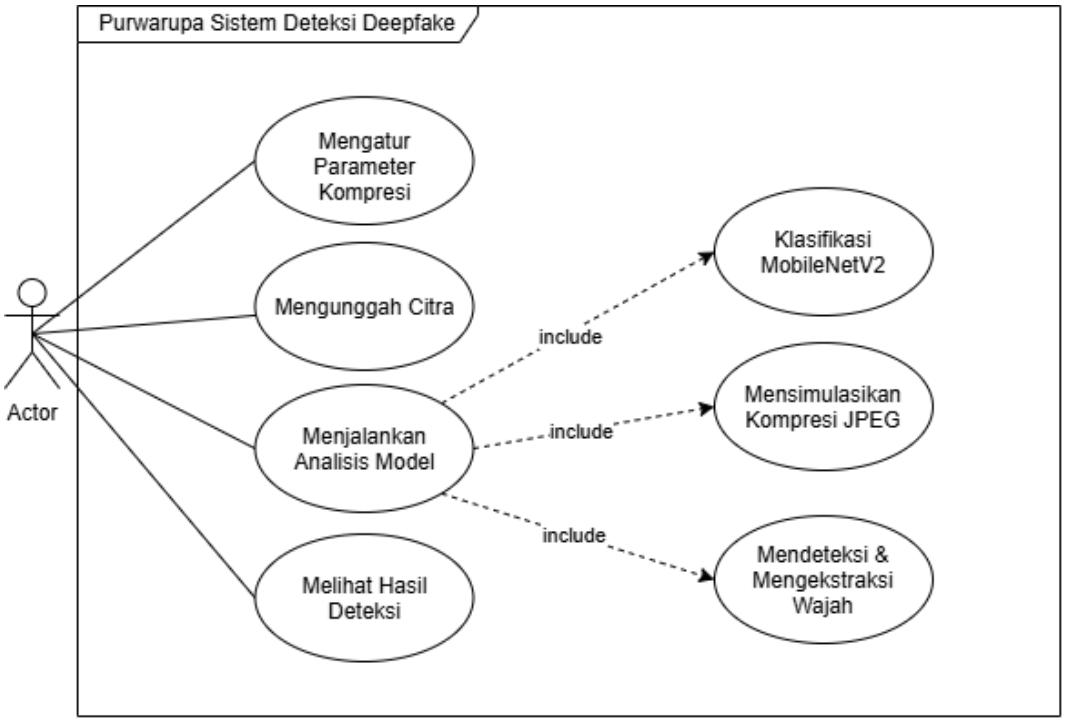
Sebaliknya, ResNet50 menunjukkan perilaku prediksi yang sangat timpang dan cenderung mengalami gejala kepanikan sistemis (*paranoid behavior*). Meskipun data uji memiliki distribusi seimbang, ResNet50 menghasilkan nilai sensitivitas (*recall*) kelas *Deepfake* yang sangat tinggi (0.92) namun dibarengi dengan nilai *recall* kelas *Real* yang sangat rendah (0.48). Karakteristik ini menunjukkan bahwa ResNet50 salah mengklasifikasikan lebih dari separuh citra wajah asli sebagai citra palsu. Tingginya angka salah tebak (*False Positive*) ini disebabkan oleh kedalaman lapisan ResNet50 yang cenderung melakukan *over-smoothing* atau generalisasi berlebih terhadap distorsi tekstur halus pada wajah, sehingga setiap keanehan piksel sekecil apa pun langsung diidentifikasi secara agresif sebagai manipulasi *deepfake*. Oleh karena itu, secara praktis, MobileNetV2 jauh lebih andal untuk diimplementasikan karena memiliki tingkat kepercayaan prediksi yang jauh lebih stabil.

4.7 Implementasi Purwarupa Sistem

Sebagai bentuk validasi praktis terhadap model kelulusan yang telah dilatih, arsitektur terbaik yaitu MobileNetV2 diintegrasikan ke dalam sebuah purwarupa aplikasi berbasis web menggunakan pustaka Streamlit. Implementasi ini bertujuan sebagai *Proof of Concept* (PoC) untuk menunjukkan bagaimana sistem kecerdasan buatan dapat bekerja secara langsung (*real-time inference*) dalam membantu pengguna akhir mengidentifikasi keaslian citra wajah yang beredar di media digital.

4.7.1 Perancangan Fungsionalitas Sistem (*Use Case Diagram*)

Untuk menggambarkan batasan sistem, fungsionalitas, serta interaksi yang dapat dilakukan oleh pengguna terhadap purwarupa aplikasi deteksi *deepfake* berbasis web, digunakan pemodelan *Use Case Diagram*.



Gambar 4. 5 *Use Case Diagram* Sistem Deteksi *Deepfake*

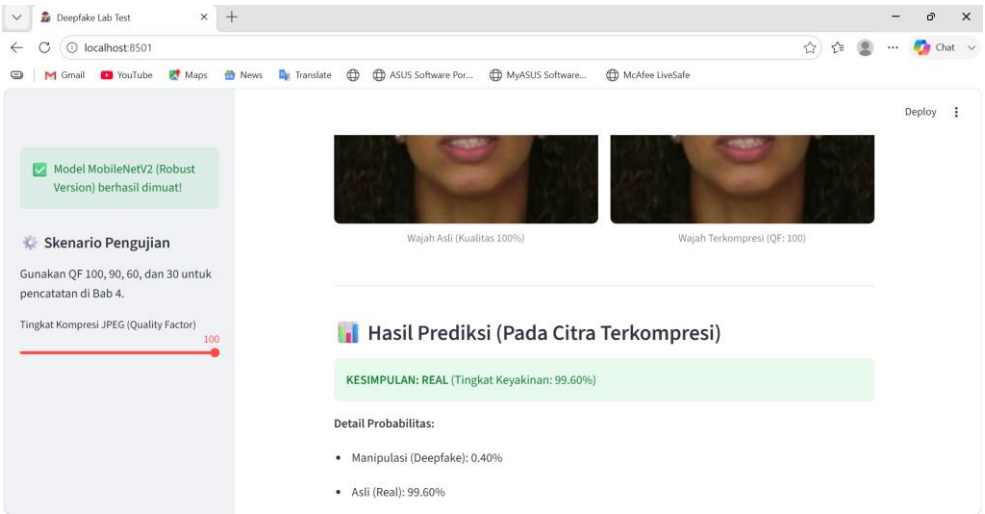
Terdapat 1 (satu) aktor utama yang berinteraksi langsung dengan sistem, yaitu Pengguna. Rincian fungsionalitas interaksi dijabarkan ke dalam deskripsi *use case* berikut:

1. Mengatur Parameter Kompresi (QF): Aktor dapat berinteraksi dengan menu *sidebar* sistem untuk menentukan tingkat kompresi JPEG (*Quality Factor*) yang akan disimulasikan pada citra.
2. Mengunggah Citra: Aktor dapat mengunggah file citra gambar statis ke dalam sistem. Sistem akan memuat dan menampilkan pratinjau gambar utuh tersebut.
3. Menjalankan Analisis Model: Setelah citra diunggah dan parameter diatur, aktor dapat memicu sistem untuk memulai proses analisis. Proses ini mencakup fungsionalitas internal otomatis (include), yaitu mengekstraksi wajah dengan OpenCV, mensimulasikan kompresi, dan melakukan klasifikasi dengan MobileNetV2.
4. Melihat Hasil Deteksi: Aktor menerima dan melihat luaran akhir dari sistem yang menampilkan perbandingan visual, kesimpulan kelas prediksi, serta persentase tingkat keyakinan model.

4.7.2 Alur Kerja dan Antarmuka Pengguna

Sistem purwarupa ini dirancang dengan alur kerja yang efisien untuk meminimalkan beban komputasi. Ketika pengguna mengunggah sebuah gambar statis melalui antarmuka web, sistem tidak langsung memasukkan gambar mentah tersebut ke dalam model. Tahap pertama yang dilakukan oleh aplikasi adalah memanggil pustaka OpenCV untuk mendeteksi keberadaan wajah dan melakukan pemotongan otomatis (*face cropping*). Proses ini sangat penting agar latar belakang (*background*) yang mengandung noise dapat dieliminasi secara tuntas.

Setelah area wajah berhasil dipotong, aplikasi Streamlit melakukan normalisasi dimensi matriks secara otomatis menjadi ukuran 224 x 224 piksel, sesuai dengan spesifikasi input mutlak dari MobileNetV2. Selanjutnya, file model mobilenetv2_celebdf.keras yang telah dimuat di latar belakang akan mengekstraksi fitur wajah tersebut dan menghasilkan nilai probabilitas biner. Hasil akhir berupa klasifikasi tegas ("REAL" atau "DEEPFAKE") beserta persentase tingkat kepercayaan model akan langsung ditampilkan pada layar pengguna melalui antarmuka yang sederhana dan interaktif.



Gambar 4. 6 Tampilan Antarmuka Purwarupa Sistem

BAB V
KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan seluruh rangkaian tahapan eksperimen, analisis metrik, dan pembahasan komparatif yang telah dilakukan mengenai analisis ketahanan model *transfer learning* terhadap kompresi citra pada klasifikasi wajah *deepfake*, maka dapat ditarik beberapa kesimpulan matematis dan empiris sebagai berikut:

1. Pada kondisi citra ideal (tanpa kompresi), arsitektur MobileNetV2 terbukti jauh lebih unggul dan objektif dibandingkan ResNet50. MobileNetV2 berhasil mencapai akurasi sebesar 83% dengan performa yang seimbang antara kelas *Real* dan *Deepfake* (*F1-score* makro sebesar 0.83). Sebaliknya, ResNet50 hanya mencapai akurasi 70% dan menunjukkan gejala *paranoid* yang ekstrem, di mana model salah mengklasifikasikan 52% citra wajah asli sebagai *deepfake* (nilai *recall* kelas *Real* hanya 48%). Hal ini membuktikan bahwa kedalaman lapisan tidak menjamin akurasi yang lebih baik pada karakteristik dataset Celeb-DF v2.
2. Degradasi kualitas citra akibat kompresi JPEG memberikan dampak penurunan performa yang sangat gradual (landai) pada MobileNetV2, yaitu hanya sebesar 2% (dari akurasi 83% pada QF 100 merosot ke 81% pada kompresi ekstrem QF 30). Hasil ini membuktikan bahwa MobileNetV2 memiliki tingkat ketahanan (*robustness*) yang sangat tinggi dalam menghadapi kerusakan artefak piksel di dunia nyata. Sementara itu, performa ResNet50 stagnan secara konstan di angka 70% pada seluruh skenario kompresi, yang menandakan arsitektur tersebut telah mencapai batas bawah pemahamannya sejak kondisi awal.

5.2 Saran

Demi pengembangan ilmu pengetahuan dan penyempurnaan sistem deteksi manipulasi digital di masa depan, beberapa saran konstruktif yang dapat diberikan untuk penelitian selanjutnya adalah:

1. Penelitian berikutnya disarankan untuk memperluas cakupan simulasi dengan menguji jenis kompresi modern lainnya yang saat ini masif digunakan oleh

platform digital, seperti format WebP atau HEIC, guna melihat konsistensi ketahanan model pada berbagai jenis ekosistem berkas.

2. Mengingat MobileNetV2 terbukti sangat ringan dan tangguh, penelitian selanjutnya dapat mencoba mengonversi model terbaik ini ke format .tflite untuk diimplementasikan secara asli (*native*) ke dalam perangkat bergerak (*smartphone* Android/iOS) guna menguji efisiensi konsumsi daya dan kecepatan *inference* langsung di perangkat pengguna.

DAFTAR PUSTAKA

[1] S. A. Gulo, A. A. Pertiwi, S. Putri, S. Nasution, and H. Syahputra, "DETEKSI DEEPFAKE DALAM CITRA MENGGUNAKAN CONVOLUTIONAL NEURAL NETWORK (CNN)," vol. 9, no. 5, pp. 8655–8660, 2025.

[2] M. A., K. S. Charan, S. BN, and S. K. R, "Deep Fake Detection using Transfer Learning: A Comparative study of Multiple Neural Networks," in *2024 International Conference on Signal Processing, Computation, Electronics, Power and Telecommunication (IConSCEPT)*, 2024, pp. 1–6. doi: 10.1109/IConSCEPT61884.2024.10627869.

[3] K. He, "Deep Residual Learning for Image Recognition".

[4] M. Sandler, M. Zhu, A. Zhmoginov, and C. V Mar, "MobileNetV2: Inverted Residuals and Linear Bottlenecks".

[5] G. K. Wallace, "The JPEG still picture compression standard," *Commun. ACM*, vol. 34, no. 4, pp. 30–44, 1991.

[6] L. A. Motalib, "Compression-Aware Hybrid Framework for Deep Fake Detection in Low-Quality Video," *IEEE Access*, vol. 13, no. July, pp. 131980–131997, 2025, doi: 10.1109/ACCESS.2025.3592358.

[7] A. K. Saxena and R. P. K. N, "Retracted: An Examination on Implementation of Deep Fake in Images Through Deep Learning," in *2022 Fourth International Conference on Emerging Research in Electronics, Computer Science and Technology (ICERECT)*, 2022, pp. 1–7. doi: 10.1109/ICERECT56837.2022.10060611.

[8] M. Sharma and M. Kaur, "A Review of Deepfake Technology: An Emerging AI Threat BT - Soft Computing for Security Applications," G. Ranganathan, X. Fernando, F. Shi, and Y. El Allioui, Eds., Singapore: Springer Singapore, 2022, pp. 605–619.

[9] M. K. S. Nam, I. Y. H. Lee, I. V May, and H. Lee, "Learning JPEG Compression Artifacts for Image Manipulation," 2022.

[10] E. D. Cannas, S. Mandelli, A. Gnutti, P. Bestagini, S. Tubaro, and P. Milano, "Is JPEG AI going to change image forensics ?," pp. 1575–1586.

[11] I. Yu, S. Nam, W. Ahn, M. Kwon, and H. Lee, "Manipulation Classification for JPEG Images Using Multi-Domain Features," pp. 210837–210854, 2020, doi: 10.1109/ACCESS.2020.3037735.

[12] A. Karathanasis and J. Violos, "A Comparative Analysis of Compression and Transfer Learning Techniques in DeepFake Detection Models," 2025.

[13] D. Tsereh, M. Mirgaleev, I. Molodetskikh, R. Kazantsev, and D. Vatolin, "JPEG AI Image Compression Visual Artifacts: Detection Methods and Dataset".

[14] Y. Lu, E. Upenik, and T. Ebrahimi, "Impact of Benign Modifications on Discriminative Performance of Deepfake Detectors".

[15] P. Grommelt, L. Weiss, F. Pfreundt, J. Keuper, H. Performance, and C.

Kaiserslautern, “Jpeg? r,” 2024.

[16] V. Verma, D. Singh, and N. Khanna, “Block-level Double JPEG Compression Detection for Image Forgery Localization,” pp. 1–5.

[17] A. Heidari, N. J. Navimipour, and M. Unal, “Deepfake detection using deep learning methods : A systematic and comprehensive review,” no. October 2023, pp. 1–45, 2024, doi: 10.1002/widm.1520.

[18] A. Hatem, S. Omnia, S. Hala, T. R. Ragab, and S. Mohsen, “Deepfake detection using convolutional vision transformers and convolutional neural networks,” *Neural Comput. Appl.*, vol. 36, no. 31, pp. 19759–19775, 2024, doi: 10.1007/s00521-024-10181-7.

[19] M. Fahad *et al.*, “Advanced deepfake detection with enhanced Resnet-18 and multilayer CNN max pooling,” *Vis. Comput.*, vol. 41, no. 5, pp. 3473–3486, 2025, doi: 10.1007/s00371-024-03613-x.

[20] H. Kabir *et al.*, “A Comprehensive Review of Machine Learning Techniques for DeepFake Detection,” vol. 2025, 2025, doi: 10.1155/acis/8883527.

[21] G. Morankar, R. Tripathi, S. Dhanore, and Y. Tiwari, “Deepfake Image Detection Using Convolutional Neural Network BT - Smart Computing Paradigms: Advanced Data Mining and Analytics,” M. Simic, V. Bhateja, A. T. Azar, and E. L. Lydia, Eds., Singapore: Springer Nature Singapore, 2025, pp. 51–62.

[22] O. Alfarouk, H. Hasan, and S. Kurnaz, “A Hybrid CNN-LSTM Approach for Precision Deepfake Image Detection Based on Transfer Learning,” pp. 1–22, 2024.

[23] P. Edwards, J. Nebel, S. Member, and D. Greenhill, “A Review of Deepfake Techniques : Architecture , Detection , and Datasets,” *IEEE Access*, vol. 12, no. October, pp. 154718–154742, 2024, doi: 10.1109/ACCESS.2024.3477257.

[24] W. Khimi, “A Systematic Review on Deep Fake Image Generation , Detection Techniques , Ethical Implications , and Overcoming Challenges,” no. 3, pp. 36–79.

[25] D. Singh, P. Singh, and R. Bhandari, “A Comprehensive Review of Deepfake Detection In Advanced Neural Network Architectures and Deep Learning Strategies,” in *2024 International Conference on Artificial Intelligence and Emerging Technology (Global AI Summit)*, 2024, pp. 1147–1152. doi: 10.1109/GlobalAISummit62156.2024.10947978.

[26] P. Ajit PaiaAjit Paia, R. Ur Rahman, and D. Singh Tomar, “A comprehensive system for detecting and verifying counterfeit images using deep neural networks,” *J. Comput. Virol. Hacking Tech.*, vol. 22, no. 1, p. 2, 2025, doi: 10.1007/s11416-025-00584-y.

[27] S. M. Mangalampalli, M. J. Mistry, A. M. Pal, and J. Pereira, “A CNN Algorithm Based DeepFake Detection System,” in *2025 12th International Conference on Computing for Sustainable Global Development (INDIACom)*, 2025, pp. 1–6. doi: 10.23919/INDIACom66777.2025.11115232.

[28] M. R. Tiwari and S. S. Patil, “Deepfake Image Detection : A Review of Existing Methods and a Hybrid CNN-Based Proposed Framework,” vol. 01043, pp. 1–9, 2025.

[29] F. Zhuang *et al.*, “A Comprehensive Survey on Transfer Learning,” pp. 1–31.

[30] L. Bai, “Research on the vector of permanent magnet synchronous motor based on MATLAB simulation,” in *2023 Prognostics and Health Management Conference (PHM)*, 2023, pp. 251–255. doi: 10.1109/PHM58589.2023.00054.

[31] L. Alzubaidi *et al.*, *Review of deep learning : concepts , CNN architectures , challenges , applications , future directions*. Springer International Publishing, 2021. doi: 10.1186/s40537-021-00444-8.

[32] I. H. Sarker, “Machine Learning: Algorithms, Real-World Applications and Research Directions,” *SN Comput. Sci.*, vol. 2, no. 3, p. 160, 2021, doi: 10.1007/s42979-021-00592-x.

[33] D. M. W. Powers, “Evaluation: from precision, recall and F-measure to ROC, informedness, markedness and correlation,” *arXiv Prepr. arXiv2010.16061*, 2020.

[34] I. Goodfellow, Y. Bengio, A. Courville, and Y. Bengio, *Deep learning*, vol. 1, no. 2. MIT press Cambridge, 2016.

[35] C. Szegedy, J. Bruna, D. Erhan, and I. Goodfellow, “Intriguing properties of neural networks,” pp. 1–10.

[36] Y. Li, X. Yang, P. Sun, H. Qi, and S. Lyu, “Celeb-DF : A Large-scale Challenging Dataset for DeepFake Forensics,” pp. 3207–3216.

[37] P. Chen, M. Xu, and X. Wang, “SS symmetry Detecting Compressed Deepfake Images Using Two-Branch Convolutional Networks with Similarity and Classifier,” pp. 1–14, 2022.

[38] Y. Patel *et al.*, “An Improved Dense CNN Architecture for Deepfake Image Detection,” *IEEE Access*, vol. 11, pp. 22081–22095, 2023, doi: 10.1109/ACCESS.2023.3251417.

[39] B. D. Satoto, A. Yasid, A. Rahmadhani, B. K. Khotimah, B. Irmawati, and S. Binti, “Deepfake detection using MobileNetV2 integrated with a support vector machine classifier,” vol. 01019, 2025.

[40] J. W. Creswell and J. D. Creswell, *Research design: Qualitative, quantitative, and mixed methods approaches*. Sage publications, 2017.

[41] M. Zakariah, M. Al-Razgan, and T. Alfakih, “Skin cancer detection with MobileNet-based transfer learning and MixNets for enhanced diagnosis,” *Neural Comput. Appl.*, vol. 36, no. 34, pp. 21383–21413, 2024, doi: 10.1007/s00521-024-10227-w.